

ANÁLISE DE PADRÕES DE DESEMPENHO NA EDUCAÇÃO SUPERIOR PRESENCIAL PAULISTA

Apresentação parcial

Drielly de Moraes
14746040

Gabriela Alcaide
14746492

Gabriela Carvalho
14749616

Rodrigo Gonçalves
14658330

Introdução

A pesquisa busca **compreender os fatores que influenciam o desempenho** dos alunos na educação superior presencial paulista, por meio da **análise dos padrões relacionados às notas dos alunos no Exame Nacional de Desempenho dos Estudantes (ENADE)**.

Para desenvolver a pesquisa, será realizada uma análise comparativa entre três grandes grupos temáticos — **percepção dos alunos, dados socioeconômicos e infraestrutura institucional** — cada um com diferentes variáveis internas. O objetivo é **identificar quais desses fatores têm maior correlação com o desempenho dos estudantes no ENADE**, fornecendo uma compreensão ampla dos elementos de impacto de desempenho.

Para isso, os dados passarão por um **pré-processamento**, e em seguida serão selecionadas as **variáveis mais correlacionadas** com as notas intra-grupos. Posteriormente, serão aplicados modelos de **Árvores de Decisão e Florestas Aleatórias** para identificar qual **grupo temático** apresenta o melhor desempenho na **classificação das notas**.

Trabalhos Correlatos

Nosso trabalho se diferencia por analisar simultaneamente fatores socioeconômicos, institucionais (infraestrutura) e de percepção dos estudantes, comparando o impacto desses fatores no desempenho acadêmico.

Souza et. al (2017)

- Buscaram identificar se um curso alcançaria um conceito igual ou superior a três no ENADE , utilizando o desempenho dos alunos no ENEM e suas características socioeconômicas.

Santos (2020)

- Mapeou as principais variáveis na determinação de desempenho acadêmico de estudantes portugueses na área de negócios. Analisou fatores socioeconômicos, demográficos, comportamentais e psicológicos

Medeiros Filho et al. (2020) e Rezende (2022)

- Com suas metodologias, investigaram a relação entre os fatores socioeconômicos e o desempenho dos estudantes selecionados no ENADE

Fernandes e Passador (2023)

- Revisaram estudos sobre acesso e qualidade da educação, destacando maior foco em fatores socioeconômicos.

Suleiman (2024)

- Estudou a influência de horas de estudo, histórico escolar, atividades extracurriculares e horas de sono no desempenho acadêmico de estudante

Martins (2025)

- Investigou, de forma comparativa, o desempenho estudantil no Enade 2022, do curso tecnológico em Processos Gerenciais, sob a ótica local, regional e nacional no âmbito brasileiro.

Fundamentos Teóricos - Correlação e Associação

Como a alteração no valor de uma variável está associada à alteração no valor de outra (Pereira, 1955)

Cramér de V

- Quantificar a força da associação entre duas variáveis categóricas nominais (Kearney, 2017)
- Varia entre 0 e 1 (Cohen, 1988)
 - 0 → não há nenhuma associação
 - 1 → há associação perfeita

Coeficiente de Spearman

- Avaliar força e direção de uma relação monotônica entre duas variáveis. Não exige linearidade (Spearman, 1904)
- Variáveis ordinais ou dados contínuos fora da distribuição normal (Rossi et al., 2018)
- Varia entre -1 a +1 (Mukaka, 2012)
 - -1 → relação monotônica negativa perfeita
 - +1 → relação monotônica positiva perfeita
 - 0 → ausência de relação monotônica

Fundamentos Teóricos - Aprendizado Supervisionado

O treinamento utiliza dados rotulados (Corcovia, 2019).

Árvore de Decisão

- Problemas de classificação ou de regressão (Carvalho, 2014)
- Árvore composta por nós internos, ramos e folhas (Lindholm, 2019; Carvalho, 2014)
- Os atributos para construção da árvore podem ser quantitativos ou categóricos (Garcia, 2003)

Floresta Aleatória

- Conjunto de árvores de decisão (Riqueti, 2018).

Metodologia

Os métodos aplicados para o desenvolvimento desse trabalho podem ser divididos em 3 grandes etapas: extração e tratamento das bases utilizadas; análise das variáveis por grupo de características e construção e avaliação dos algoritmos de classificação escolhidos.

Extração e tratamento das bases

- Microdados do ENADE (2023), Questionário do Estudante (2023) e dados do Censo da Educação Superior (2023)
- Construção das bases dos grupos temáticas utilizadas em todas as etapas do projeto 🔍


Análise das variáveis por grupo de características

- Aplicação de estatísticas descritivas para percepção inicial dos grupos temáticos
- Identificação dos fatores (variáveis) com maior correlação com o desempenho dos estudantes através das correlações Cramér de V e de Spearman

Construção e avaliação dos algoritmos de classificação

- Construção de modelos de Árvore de Decisão para cada grupo temático (biblioteca *scikit-learn*)
 - Divisão estratificada dos dados de treino e teste
 - Realização de *Grid Search* para encontrar o melhor conjunto de parâmetros a cada modelo
- Avaliação dos modelos finais com métricas de desempenho
 - Acurácia, Precisão, Sensibilidade, F-score e Matrizes de confusão

Metodologia




Resultados parciais - Análise preliminar do desempenho dos estudantes

Estatística	Valor
Mínimo	18.90
1º Quartil (Q1)	35.95
Quantil 33%	39.65
Mediana	45.30
Quantil 66%	49.57
3º Quartil (Q3)	52.21
Máximo	76.99
Média	44.86
Moda	40.97
Desvio Padrão	10.18

Categorização da variável

- 0 a 35,95 → baixo
- > 35,95 a 45,30 → médio baixo
- > 45,30 a 52,21 → médio alto
- > 52,21 a 76.99 → alto



Resultados parciais - Variáveis principais em cada grupo temático

Variáveis com maior correlação / associação com o desempenho.

Variáveis de Infraestrutura

- Curso
- Município da instituição
- Município da reitoria
- Mantenedora da instituição;
- Bairro;
- Tipo da rede de ensino;
- Quantidade total de docentes em exercício em tempo integral com dedicação exclusiva.


Resultados parciais - Variáveis principais em cada grupo temático

Variáveis com maior correlação / associação com o desempenho.

Variáveis de Infraestrutura

Estado de São Paulo

Comando da Aeronáutica



Mantenedora

Resultados parciais - Variáveis principais em cada grupo temático

Variáveis com maior correlação / associação com o desempenho.

Variáveis de Infraestrutura

TP_REDE	Media	Moda
1	55.614046	alto
2	43.133219	baixo

Tipo da rede de ensino
(1: pública / 2: privada)

Resultados parciais - Variáveis principais em cada grupo temático

Variáveis com maior correlação / associação com o desempenho.


Variáveis de Percepção do Estudante

- As **relações professor-aluno** ao longo do curso estimularam você a estudar e aprender?
- Foram oferecidas **oportunidades para os estudantes superarem dificuldades** relacionadas ao processo de formação?
- A coordenação do curso esteve disponível para **orientação acadêmica** dos estudantes?
- As atividades realizadas durante seu **TCC contribuíram para qualificar sua formação profissional?**
- Os estudantes participaram de **avaliações periódicas do curso?**
- A instituição contou com biblioteca virtual ou conferiu **acesso a obras disponíveis em acervos virtuais?**
- A instituição dispôs de **refeitório, cantina e banheiros em condições adequadas** que atenderam as necessidades dos seus usuários?

Resultados parciais - Variáveis principais em cada grupo temático

Variáveis com maior correlação / associação com o desempenho.

Variáveis de Percepção do Estudante




TCC contribuiu para qualificação profissional (1: discordo totalmente / 2: discordo / 3: discordo parcialmente / 4: concordo parcialmente / 5: concordo / 6: concordo totalmente / 7: não sei responder / 8: não se aplica)

Resultados parciais - Variáveis principais em cada grupo temático

Variáveis com maior correlação / associação com o desempenho.

Variáveis de Percepção do Estudante



Participaram de avaliações periódicas do curso
(1: discordo totalmente / 2: discordo / 3: discordo parcialmente /
4: concordo parcialmente / 5: concordo / 6: concordo totalmente
/ 7: não sei responder / 8: não se aplica)

Resultados parciais - Variáveis principais em cada grupo temático

Variáveis com maior correlação / associação com o desempenho.


Variáveis de Situação Socioeconômica

- **Sexo**
- Qual alternativa a seguir melhor descreve sua **situação financeira** (incluindo bolsas)?
- Qual alternativa a seguir melhor descreve sua **situação de trabalho** (exceto estágio ou bolsas)?
- Que tipo de bolsa de estudos ou financiamento do curso você recebeu para **custear todas ou a maior parte das mensalidades**?
- Em que **tipo de escola** você cursou o ensino médio?
- Quantas **horas por semana, aproximadamente, você dedicou aos estudos**, excetuando as horas de aula?
- Qual o principal **motivo para você ter escolhido este curso**?

Resultados parciais - Variáveis principais em cada grupo temático

Variáveis com maior correlação / associação com o desempenho.

Variáveis de Situação Socioeconômica




Situação de trabalho
A = Não estou trabalhando
B = Trabalho eventualmente
C = Trabalho até 20 horas semanais
D = Trabalho de 21 a 39 horas semanais
E = Trabalho 40 horas semanais ou mais

Resultados parciais - Variáveis principais em cada grupo temático

Variáveis com maior correlação / associação com o desempenho.

Variáveis de Situação Socioeconômica



Situação financeira

- A = Não tenho renda - gastos financiados por programas governamentais
- B = Não tenho renda - gastos financiados pela família ou outras pessoas
- C = Tenho renda, mas recebo ajuda da família ou de outras pessoas
- D = Tenho renda e não preciso de ajuda para financiar meus gastos
- E = Tenho renda e contribuo com o sustento da família
- F = Sou o principal responsável pelo sustento da família

Resultados parciais - Árvores de Decisão

Construção dos modelos:

- Utilização das variáveis com maior correlação em cada grupo temático - resultados da etapa anterior
- Divisão estratificada: 80% para treino e 20% para teste
 - Um curso pertence ao mesmo grupo para todos os modelos
- Aplicação de Grid-Search para escolha de melhores hiperparâmetros
 - Critério de Impureza - Gini ou Entropia
 - Profundidade máxima da árvore
 - Número mínimo de amostras por folha
 - Número mínimo de amostras para divisão interna

Resultados grid-search:




Grupo temático	Critério Impureza	Profundidade Máxima	Núm. mínimo de amostras por folha	Núm. mínimo de amostras por divisão interna
Percepção	Gini	-	1	5
Infraestrutura	Entropia	5	2	2
Socioeconômico	Entropia	3	1	2

Resultados parciais - Árvores de Decisão

Resultados - métricas de avaliação (médias macro):

Grupo temático	Acurácia	Precisão	Sensibilidade	Medida F1
Percepção	0,2872	0,2872	0,2861	0,2820
Infraestrutura	0,6011	0,5881	0,6007	0,5733
Socioeconômico	0,5319	0,5241	0,5295	0,4853

Resultados - matrizes de confusão:



Conclusão

Buscamos **definir o eixo temático com maior influência sobre o desempenho dos estudantes** → direcionamento para **políticas públicas acertivas** de melhoria da educação

Aplicação de modelos de Árvore de Decisão

- O conjunto de **variáveis de Infraestrutura** teve o melhor poder discriminatório
- Os modelos tendem a separar com **maior precisão os extremos do desempenho** (baixo e alto), mas apresentam maior confusão nas classes intermediárias (médio baixo e médio alto).

OBRIGADO!

Drielly de Moraes

Gabriela Alcaide

Gabriela Carvalho

Rodrigo Gonçalves