

Impacto das dimensões socioeconômica, percepção do estudante e infraestrutura no desempenho de cursos na educação superior presencial paulista

Title: *Impact of socioeconomic, student perception and infrastructure dimensions on the performance of on-campus higher education programs in São Paulo*

Título: *Impacto de las dimensiones socioeconómica, percepción del estudiante y infraestructura en el desempeño de los cursos de educación superior presencial en São Paulo*

Drielly de Moraes Guerreiro
Universidade de São Paulo (USP)
ORCID: [0000-0000-0000-0000](https://orcid.org/0000-0000-0000-0000)
driellymoraes@usp.br

Gabriela Carvalho Vitorino
Universidade de São Paulo (USP)
ORCID: [0000-0000-0000-0000](https://orcid.org/0000-0000-0000-0000)
gabrielaventurin@usp.br

Gabriela Alcaide
Universidade de São Paulo (USP)
ORCID: [0000-0000-0000-0000](https://orcid.org/0000-0000-0000-0000)
gabriela.alcaide@usp.br

Rodrigo Gonçalves Cardoso
Universidade de São Paulo (USP)
ORCID: [0000-0000-0000-0000](https://orcid.org/0000-0000-0000-0000)
ديو.gcardoso@usp.br

Resumo

Este estudo investiga as dimensões que influenciam o desempenho dos estudantes no Exame Nacional de Desempenho dos Estudantes (ENADE), com foco em três grupos de variáveis: (1) socioeconômicas, (2) de percepção dos alunos sobre a formação acadêmica e (3) de infraestrutura dos cursos de Ensino Superior. Utilizando microdados do ENADE do ano 2023 e do Censo da Educação Superior, as notas dos cursos foram classificadas em duas categorias: baixa e alta. Após o tratamento dos dados, foram aplicadas técnicas estatísticas, como o coeficiente de Spearman e o Cramér de V, para identificar as variáveis mais correlacionadas ao desempenho. Em seguida, as variáveis selecionadas de cada dimensão foram submetidas a modelos supervisionados, como Árvores de Decisão e Florestas Aleatórias, para avaliar o poder preditivo de cada dimensão. O objetivo é verificar quais dessas dimensões exercem maior influência sobre os resultados dos estudantes e gerar insumos para políticas públicas e estratégias institucionais de melhoria da qualidade do ensino superior.

Palavras-chave: ENADE; desempenho acadêmico; fatores socioeconômicos; infraestrutura educacional; aprendizado de máquina.

Abstract

This study investigates the dimensions that influence student performance on National Student Performance Exam (ENADE), focusing on three groups of variables: (1) socioeconomic, (2) students' perceptions of their academic education and (3) Higher Education course infrastructure. Using ENADE microdata from the year 2023 and data from the Higher Education Census, course scores were classified into two categories: low and high. After data preprocessing, statistical techniques such as Spearman's coefficient and Cramér's V were applied in order to identify the most correlated variables with performance. Then, the selected variables from each dimension were submitted to supervised models, such as Decision Trees and Random Forests, to assess the predictive power of each dimension. The objective is to determine which of these dimensions exert the greatest influence on student performance and to provide insights for public policies and institutional strategies aimed at improving the quality of higher education.

Keywords: ENADE; academic performance; socioeconomic factors; educational infrastructure; machine learning.

Resumen

Este estudio investiga las dimensiones que influyen en el desempeño de los estudiantes en el Examen Nacional de Desempeño de los Estudiantes (ENADE), con énfasis en tres grupos de variables: (1) socioeconómicas, (2) de percepción de los alumnos sobre la formación académica y (3) de infraestructura de los cursos de Educación Superior. Utilizando microdatos del ENADE del año 2023 y del Censo de Educación Superior, las calificaciones de los cursos fueron clasificadas en dos categorías: baja y alta. Después del procesamiento de los datos, se aplicaron técnicas estadísticas, como el coeficiente de Spearman y el V de Cramér, para identificar las variables más correlacionadas con el desempeño. Luego, las variables seleccionadas de cada dimensión fueron sometidas a modelos supervisados, como Árboles de Decisión y Bosques Aleatorios, con el fin de evaluar el poder predictivo de cada dimensión. El objetivo es verificar cuáles de estas dimensiones ejercen mayor influencia sobre los resultados de los estudiantes y generar insumos para políticas públicas y estrategias institucionales orientadas a mejorar la calidad de la educación superior.

Palabras clave: ENADE; desempeño académico; factores socioeconómicos; infraestructura educativa; aprendizaje automático.

1 Introdução

O desempenho dos alunos em instituições de ensino superior constitui um fator de extrema relevância não apenas para as próprias universidades, mas também para o desenvolvimento social e econômico do país. O rendimento acadêmico está diretamente associado à formação de profissionais mais qualificados, ao fortalecimento da competitividade nacional e à promoção de inovação. Nesse sentido, compreender os elementos que influenciam esse desempenho, especialmente quando avaliado por meio da prova do Exame Nacional de Desempenho de Estudantes (ENADE), torna-se essencial para subsidiar políticas públicas mais eficazes, apoiar a gestão institucional e fornecer insumos que possibilitem aprimorar a qualidade do ensino. Assim, o estudo do desempenho acadêmico extrapola o interesse meramente acadêmico e revela sua importância como ferramenta estratégica para a sociedade.

Apesar de haver avanços recentes em pesquisas que buscam identificar os fatores relacionados ao desempenho estudantil, ainda permanecem lacunas importantes, principalmente quando se considera a complexidade e a diversidade da vivência universitária. Muitos trabalhos anteriores concentraram-se em aspectos isolados, como o perfil socioeconômico (Medeiros Filho et al., 2020; Rezende, C.C., 2022) ou o desempenho em avaliações específicas, sem integrar de maneira abrangente os múltiplos elementos que compõem a realidade do estudante. Esse cenário reforça a necessidade de estudos que articulem diferentes grupos temáticos, desde a percepção dos alunos em relação aos cursos até a infraestrutura das instituições, de modo a evidenciar, com maior precisão, quais fatores exercem maior influência sobre os resultados obtidos. A abordagem integrada e multidimensional, portanto, representa um caminho promissor para análises mais consistentes e para a formulação de estratégias assertivas de melhoria.

Diversos estudos prévios já buscaram compreender o impacto de fatores variados no desempenho acadêmico. Silva (2018), por exemplo, investigou o impacto de mudanças de residência, região de origem e expectativas de dificuldades no rendimento de alunos do primeiro ano de Medicina da Universidade da Beira Interior. O autor concluiu que as dificuldades antecipadas pelos estudantes foram as variáveis com maior relação com o desempenho, ainda que sua pesquisa não tenha considerado dimensões como fatores socioeconômicos ou de infraestrutura institucional. Já Medeiros Filho et al. (2020) analisaram os resultados do ENADE de mais de 15 mil estudantes e demonstraram que aqueles com apoio financeiro de bolsas ou programas governamentais obtiveram melhor desempenho, enquanto alunos de baixa renda ou que trabalhavam em regime integral tiveram resultados inferiores. Esses trabalhos reforçam a importância de ampliar a análise para diferentes dimensões da experiência universitária, o que motiva a presente investigação.

Diante desse panorama, formula-se a seguinte questão de pesquisa: entre as diversas dimensões relacionadas à trajetória universitária, quais delas exercem maior influência sobre o desempenho dos alunos nos cursos de educação superior presencial paulista no ENADE? A investigação busca considerar três dimensões com foco em três grupos de variáveis: (1) percepções dos estudantes sobre a formação recebida, (2) socioeconômicas e (3) condições de infraestrutura das instituições, permitindo identificar combinações mais significativas e capazes de direcionar ações efetivas.

Com base nesse problema, o presente trabalho tem como objetivo principal reunir e analisar dados provenientes do ENADE e dos microdados do Censo da Educação Superior, de forma a

identificar quais dimensões apresentam maior correlação com o desempenho acadêmico médio dos alunos nos cursos, seja de maneira positiva ou negativa. A intenção é compreender em que medida variáveis de diferentes naturezas se relacionam com os resultados dos estudantes, oferecendo subsídios para a elaboração de políticas educacionais mais eficazes e estratégias de gestão mais alinhadas às necessidades reais das instituições.

A metodologia proposta fundamenta-se na utilização de dados do ENADE e dos microdados da Educação Superior referentes a cursos presenciais, públicos e privados do estado de São Paulo. Os dados foram agrupados por curso, e depois analisados por meio de medidas de correlação estatística, a fim de identificar os fatores mais relevantes em cada dimensão. Por fim, os conjuntos de variáveis selecionadas de cada dimensão foram submetidos a algoritmos supervisionados de classificação, como Árvore de Decisão e Florestas Aleatórias. Esse percurso metodológico permitirá tanto compreender a importância relativa de cada dimensão quanto verificar a capacidade preditiva dos modelos em relação ao desempenho dos estudantes.

Além desta introdução, o trabalho está estruturado nas seguintes seções: Fundamentos Teóricos, que apresentam os conceitos e definições centrais; Correlação e Associação, que detalham os métodos estatísticos utilizados, como o Cramér de V e o Coeficiente de Spearman; Aprendizado de Máquina, que aborda os algoritmos supervisionados aplicados à análise; Exame Nacional de Desempenho dos Estudantes (ENADE), que contextualiza a avaliação utilizada; Trabalhos Correlatos, que situam esta pesquisa em relação a estudos anteriores; Método, que descreve os procedimentos adotados; e Resultados, em que são apresentadas as variáveis principais em cada dimensão. Por fim, o trabalho se encerra com as Referências, que sustentam teoricamente a investigação.

2 Fundamentos teóricos

2.1 Exame Nacional de Desempenho dos Estudantes (ENADE)

O Exame Nacional de Desempenho dos Estudantes integra o Sistema Nacional de Avaliação da Educação Superior (Sinaes) e tem como objetivo avaliar o processo de aprendizagem no ensino superior brasileiro, com base nas diretrizes curriculares dos cursos de graduação selecionados a cada ano (INEP, 2025). Além de verificar a compreensão dos conteúdos específicos, o exame também avalia competências necessárias para a interpretação de temas relacionados ao campo profissional escolhido, envolvendo outras áreas do conhecimento. Anualmente, o MEC define as áreas que serão avaliadas pelo ENADE, tomando como referência as propostas apresentadas pela Conaes, órgão responsável pela coordenação e supervisão do Sinaes.

A prova é composta por 40 questões, sendo 10 destinadas à formação geral e 30 à formação específica da área, ambas contendo itens discursivos e de múltipla escolha. A etapa de formação geral inclui 10 questões, 2 discursivas e 8 objetivas, formuladas a partir de situações-problema e estudos de caso. Já a etapa específica de cada área do conhecimento reúne 30 questões, sendo 3 discursivas e 27 de múltipla escolha, também baseadas em situações-problema e estudos de caso (INEP, 2025). Além das questões, no dia da prova, os estudantes devem responder obrigatoriamente ao Questionário do Estudante, que coleta informações sobre seu perfil e contexto formativo, e ao Questionário de Percepção da Prova, que registra a avaliação dos participantes

sobre a experiência de realização do exame.

O desempenho dos estudantes no ENADE é avaliado pelo Conceito Enade, aplicado pelo Inep. Ele é calculado a partir das notas da prova e indica a qualidade da formação oferecida pelas instituições, considerando conhecimentos, competências e habilidades desenvolvidas ao longo do curso. A pontuação varia de 1 a 5 e serve para orientar estudantes, apoiar melhorias internas e subsidiar políticas públicas. Os resultados do exame e dos questionários compõem os Indicadores de Qualidade da Educação Superior, também avaliados na escala de 1 a 5.

O ENADE do ano 2023, utilizado nessa pesquisa, avaliou os estudantes dos cursos de bacharelado e superiores de tecnologia em: Agronomia, Arquitetura e Urbanismo, Biomedicina, Enfermagem, Engenharia Ambiental, Engenharia Civil, Engenharia de Alimentos, Engenharia de Computação, Engenharia de Controle e Automação, Engenharia de Produção, Engenharia Elétrica, Engenharia Florestal, Engenharia Mecânica, Engenharia Química, Farmácia, Fisioterapia, Fonoaudiologia, Medicina, Medicina Veterinária, Nutrição, Odontologia, Zootecnia, Agronegócio, Estética e Cosmética, Gestão Ambiental, Gestão Hospitalar, Radiologia, Segurança no Trabalho (INEP 2023) e cursos derivados.

2.2 Censo de Educação Superior

O Censo da Educação Superior busca retratar o ensino superior em um determinado ano. Realizado anualmente pelo Inep, o censo inclui todas as Instituições de Educação Superior (IES) registradas no Sistema e-MEC, sejam públicas, privadas, comunitárias ou filantrópicas. Os dados são coletados por recenseadores indicados pelas próprias instituições, por meio do sistema Censup, garantindo que as informações sejam consistentes. A pesquisa reúne informações sobre cursos, vagas, alunos, professores, modalidades de ensino, infraestrutura e políticas institucionais, permitindo acompanhar a trajetória dos estudantes desde o ingresso na graduação. (INEP, 2023).

As informações do censo são usadas para oferecer dados confiáveis sobre o ensino superior brasileiro, ajudando na criação e avaliação de políticas públicas, além de apoiar programas de melhoria da qualidade da educação. O Inep também calcula indicadores que permitem compreender os resultados e acompanhar a trajetória dos estudantes. Todos os microdados, painéis e indicadores estão disponíveis no site do Inep, permitindo que pesquisadores, estudantes e órgãos públicos ou privados tenham acesso a informações detalhadas para estudos e iniciativas (INEP 2025).

Para esta análise, utilizamos os dados do ano de 2023, disponibilizados pelo site Base dos Dados. Os dados utilizados incluem informações sobre as instituições de ensino superior, cursos presenciais e a distância, cursos sequenciais, vagas oferecidas, inscrições, matrículas, ingressantes e concluintes, além de informações sobre docentes nas diferentes formas de organização acadêmica e categoria administrativa (Base dos Dados, 2025).

2.3 Correlação e Associação

Correlação é uma ferramenta estatística que verifica a existência de relações, causais ou não, entre variáveis aleatórias (Figueiredo Filho Silva Júnior, 2009). Ela mensura como a alteração no valor de uma variável está associada à alteração no valor de outra (Pereira, 1951). A seleção do coeficiente apropriado depende da natureza dos dados e do tipo de relação entre eles (Lira, 2004).

2.3.1 Cramér de V

Cramér de V é uma medida estatística utilizada para quantificar a força da associação entre duas variáveis categóricas nominais, ou seja, variáveis cujos valores são nomes ou rótulos sem uma ordem intrínseca (como "estado civil" e "preferência musical") (Allen, 2017).

Seu propósito é condensar a complexidade de uma relação em um único número, que varia de 0 a 1. Um valor de 0 indica que não existe qualquer associação entre as variáveis, sendo variáveis completamente independentes. Em contrapartida, um valor de 1 representa uma associação perfeita, em que conhecer a categoria de uma variável permite prever com exatidão a categoria da outra (Cohen, 1988).

2.3.2 Coeficiente de Spearman

O coeficiente de correlação de postos de Spearman, denotado por ρ (), é uma medida não paramétrica que avalia a força e a direção de uma relação monotônica entre duas variáveis. Diferentemente do coeficiente de Pearson, que mede associações estritamente lineares, o de Spearman não exige que a relação seja linear, mas sim que seja consistente em sua direção, ou seja, à medida que uma variável aumenta, a outra consistentemente aumenta ou diminui (Spearman, 1904). Seu uso é indicado em duas situações principais: quando as variáveis são de natureza ordinal (como escalas Likert ou classificações) ou quando dados contínuos violam as premissas para o uso da correlação de Pearson, como a ausência de distribuição normal (Miot 2018).

Seu valor varia de -1 a +1, em que o sinal indica a direção da associação (positiva ou negativa) e a magnitude aponta a força. Um valor de +1 indica uma relação monotônica positiva perfeita, -1 representa uma relação monotônica negativa perfeita, e valores próximos de zero sugerem a ausência de uma relação monotônica (Mukaka, 2012).

2.4 Critério de Informação Bayesiano (BIC)

O Critério de Informação Bayesiano (BIC) é utilizado na seleção entre modelos estatísticos, buscando equilibrar qualidade de ajuste e complexidade, seguindo o princípio da parcimônia (Schwarz, 1978). A inclusão de mais parâmetros tende a melhorar o ajuste medido pela verossimilhança, mas pode levar ao sobreajuste, capturando ruído em vez da estrutura real dos dados (Drton et al., 2017). O BIC incorpora explicitamente uma penalização ao número de parâmetros, sendo definido por $BIC = -2\ln(\hat{L}) + k\ln(n)$ (Burnham et al., 2004). Nessa formulação, o termo de verossimilhança representa o ajuste do modelo, enquanto o segundo termo penaliza o aumento da complexidade (Underhill, 2015). Entre modelos candidatos, seleciona-se aquele com menor BIC. Assintoticamente, quando o tamanho da amostra cresce, o BIC possui consistência estatística, garantindo a escolha do modelo verdadeiro caso ele esteja no conjunto avaliado (Aho et al., 2014).

2.5 Aprendizado de Máquina

Nesta seção são descritas as técnicas de aprendizado não supervisionado e supervisionado utilizadas neste trabalho.

2.5.1 Modelagem de Mistura Gaussiana (GMM)

A Modelagem de Mistura Gaussiana (GMM) é uma técnica de clusterização não supervisionada e baseada em probabilidade (Huang et al, 2023). Ela opera sob a premissa fundamental de que os dados observados são, na verdade, uma mistura de K subpopulações distintas, onde cada subpopulação segue sua própria distribuição Gaussiana (normal) (Economou, 2023). A principal aplicação do GMM é modelar com eficácia conjuntos de dados com múltiplas regiões de densidade, onde uma única distribuição seria inadequada (Economou, 2023).

A densidade de probabilidade de um GMM é definida como uma soma ponderada dos K componentes Gaussianos (Huang et al, 2023). Cada componente k é definido por três parâmetros: o peso da mistura (π_k), que representa a prevalência ou probabilidade a priori daquele cluster; o vetor de média (μ_k), que define o seu centroide; e a matriz de covariância (Σ_k), que descreve sua forma, dispersão e orientação no espaço (Huang et al, 2023).

A estimação desses parâmetros é realizada iterativamente através do algoritmo Expectation-Maximization (EM) (Economou, 2023). O algoritmo alterna entre o "E-step"(Expectativa), que calcula as probabilidades posteriores (ou responsabilidades) de cada ponto de dado pertencer a cada um dos K clusters, e o "M-step"(Maximização), que atualiza os parâmetros (π_k, μ_k, Σ_k) para maximizar a verossimilhança dos dados (Huang et al, 2023). Esse processo calcula a probabilidade de um ponto pertencer a todos os clusters, em vez de uma atribuição rígida a apenas um (Wenskovitch, 2019).

2.5.2 Algoritmos Supervisionados

Em problemas supervisionados, os dados que alimentam o treinamento do algoritmo são rotulados. O objetivo do aprendizado é prever as classes de registros cujos rótulos ainda não são conhecidas pelo algoritmo (Corcovia, 2019).

Árvore de Decisão

Árvore de Decisão é um modelo de Aprendizado Supervisionado, utilizado tanto para problemas de Classificação quanto de Regressão (Carvalho, 2014).

A estrutura da Árvore é composta por nós internos, ramos e folhas. Cada nó interno da Árvore corresponde a um teste sobre um atributo dos dados. Ramos são as arestas que ligam os nós, e representam os possíveis resultados dos testes. Folhas são os nós finais da Árvore, que contêm a classificação predita para o dado (Lindholm, 2019; Carvalho, 2014).

Floresta Aleatória

Floresta aleatória é um conjunto de Árvores de Decisão heterogêneas (Riqueti, 2018). Para isso, é necessário construir cada Árvore de forma aleatória (Lindholm, 2019). Isso pode ser garantido através das seguintes técnicas: treinar cada Árvore com um subconjunto diferente dos dados de treinamento, possivelmente repetidos; e dispôr subconjuntos de atributos diferentes para o treinamento de cada Árvore (Riqueti, 2018).

Avaliação de Algoritmos de Aprendizado Supervisionado

Matriz de Confusão é uma matriz quadrada que relaciona a classes real e predita de cada dado. A interpretação da matriz permite identificar o comportamento do modelo sobre cada classe

dos dados (Sathyanarayanan, 2024; Tiwari, 2022).

Em problemas de Classificação binária, a classe de interesse do estudo é tratada como positiva. Nesse sentido, são definidos os seguintes valores para avaliação do modelo: TP (True Positive), quando a classe real do dado e a classe predita pelo modelo são positivas; TN (True Negative), quando a classe real do dado e a classe predita pelo modelo são negativas; FP (False Positive), quando a classe real do dado é negativa e a classe predita pelo modelo é positiva; e FN (False Negative), quando a classe real do dado é positiva e a classe predita pelo modelo é negativa (Sathyanarayanan, 2024; Tiwari, 2022). Em problemas de Classificação multiclasse, esses valores são calculados separadamente para cada classe dos dados, que é dada como positiva a cada iteração de cálculo (Sathyanarayanan, 2024).

Existem diferentes métricas para avaliação de um modelo de Classificação. Acurácia mede a proporção de predições corretas ($TP + TN$) dentre todas as predições do modelo ($TP + TN + FP + FN$). Precisão mede a proporção de verdadeira positivos TP dentre todas as predições positivas ($TP + FP$). Recall mede a proporção de predições positivas TP dentro todos os casos positivos ($TP + FN$). (Sathyanarayanan, 2024; Tiwari, 2022)

3 Trabalhos Correlatos

Silva (2018) investigou o impacto de mudanças de residência, região de origem e opinião prévia sobre dificuldades que seriam enfrentadas ao longo do curso no desempenho acadêmico dos estudantes no 01º ano de Medicina da UBI (Universidade da Beira Interior). Utilizou estatísticas descritivas e inferência, concluindo que, entre os fatores observados, o que teve maior relação com o desempenho foram dificuldades antecipadas. Diferentemente do presente estudo, não trabalha a influência das dimensões socioeconômica, infraestrutura e percepção dos estudantes no desempenho acadêmico dos cursos.

Santos (2020) mapeou as principais variáveis na determinação de desempenho acadêmico de estudantes portugueses na área de negócios. Analisou fatores socioeconômicos, demográficos, comportamentais e psicológicos. Formulou hipóteses de pesquisa e aplicou metodologias de teste de hipóteses, como teste T Student, Mann-Whitney e Anova. Diferente do presente estudo, Santos (2020) considera apenas a Revisão da Literatura para escolher as variáveis que seriam consideradas na análise. Além disso, não trata a realidade do estado de São Paulo.

Suleiman (2024) estudou a influência de horas de estudo, histórico escolar, atividades extracurriculares e horas de sono no desempenho acadêmico de estudantes. Aplicou estudos de correlação e Regressão Linear. Diferente do presente estudo, não comparou a influência de diferentes dimensões no desempenho e utilizou apenas Revisão da Literatura para escolha de variáveis.

Medeiros Filho et al. (2020) investigaram a relação entre os fatores socioeconômicos e o desempenho dos estudantes selecionados no ENADE. A pesquisa utilizou dados de 15.400 estudantes que realizaram a prova em 2017. Os autores concluíram que os estudantes com melhor desempenho foram aqueles com gastos financiados por programas governamentais ou bolsas e que não trabalhavam. Por outro lado, os que obtiveram menor desempenho foram os que tinham renda familiar de até 1,5 salário mínimo e os que trabalhavam 40 horas ou mais semanais. O presente estudo se diferencia por abordar dimensões além da socioeconômica, explorando também

as dimensões de infraestrutura e percepção.

Rezende, C.C. (2022) realizaram uma análise de como os fatores socioeconômicos dos estudantes respondentes do ENADE se relacionaram a nota dos mesmos na avaliação. Na conclusão do trabalho mostrou-se que as variáveis mais relevantes foram a renda familiar, a participação em intercâmbio e bolsa acadêmica, o tipo de financiamento da mensalidade e o tipo de escola do ensino médio. O atual trabalho possui como principal diferença uma maior abrangência quanto às dimensões abordadas (foram incluídas as dimensões de percepção e de infraestrutura).

Martins (2025) investigou, de forma comparativa, o desempenho estudantil no ENADE 2022, do curso tecnológico em Processos Gerenciais, sob a ótica local, regional e nacional no âmbito brasileiro. Os principais resultados indicam um melhor desempenho da maioria das regiões administrativas e metropolitanas do Estado de São Paulo, com destaque a região de Presidente Prudente e São José do Rio Preto, comparados com o Estado de São Paulo, Região Sudeste do Brasil e a Média Nacional. A principal diferença em relação ao presente trabalho é o grupo de análise, sendo o principal público deste trabalho os alunos do curso tecnológico em Processos Gerenciais, ou seja, a diminuição da amostra de pesquisa, além da comparação com a região Sudeste.

Souza et al. (2017) buscaram identificar se um curso alcançaria um conceito igual ou superior a três no ENADE, utilizando o desempenho dos alunos no ENEM e suas características socioeconômicas. A metodologia Cross Industry Standard Process for Data Mining (CRISP-DM) foi utilizada para extrair conhecimento das bases de dados. Os autores concluíram que a Unidade da Federação (UF) e o tempo entre a conclusão do ensino médio e o início da graduação são as variáveis que mais influenciam no resultado. As principais diferenças em relação ao presente trabalho estão na utilização do conceito como variável alvo, na utilização dos dados do ENEM e na não utilização das variáveis de infraestrutura e de percepção dos alunos.

Fernandes e Passador (2023) destacam a preocupação constante com a ampliação do acesso à educação, mas a negligência da qualidade do que já é oferecido. Os autores destacam a diferença na quantidade de estudos encontrados, sendo 20 voltados às características socioeconômicas dos estudantes e apenas 8 sobre a infraestrutura das instituições. De modo geral, os trabalhos revisados indicam que os fatores socioeconômicos têm maior impacto no desempenho acadêmico dos alunos do que os aspectos institucionais. Diferentemente de Fernandes e Passador (2023), nosso estudo não se caracteriza como uma revisão, mas sim como uma análise comparativa própria entre dimensões socioeconômica, infraestrutura e de percepção dos estudantes, aprofundando a relação desses aspectos com o desempenho acadêmico.

4 Método

Para a realização do presente estudo, foram aplicadas técnicas de tratamento, análise e predição de dados a fim de observar o impacto de diferentes dimensões no desempenho acadêmico de estudantes concluintes do ensino superior no ENADE. Nesta análise, selecionamos três grupos temáticos com potencial influência no desempenho dos estudantes na visão dos autores: características socioeconômicas, infraestrutura da instituição de ensino superior ofertante do curso e percepção dos estudantes sobre a formação.

Após observação inicial dos Microdados do ENADE disponibilizados pelo Inep no *site* do

instituto, considera-se, respectivamente, as respostas do Questionário do Estudante, a avaliação dos estudantes sobre seu processo formativo e as informações do Censo da Educação Superior acerca das Instituições de Ensino Superior (IES), também disponibilizadas pelo Inep, fontes adequadas para a captura das características socioeconômicas, de percepção dos estudantes e de infraestrutura das IES.

4.1 Pré-processamento

A primeira etapa do projeto consistiu no tratamento e pré-processamento dos dados. Inicialmente, buscou-se agrupar as notas dos estudantes utilizando uma chave primária que representasse de forma única o curso ao qual cada aluno estava vinculado. Essa estratégia foi necessária porque, ao optar pelo uso dos dados mais recentes disponibilizados pelo Enade (2023), verificou-se a ausência de identificadores individuais do aluno e de suas respectivas notas, ocultados em conformidade com a Lei Geral de Proteção de Dados (LGPD). Para assegurar a unicidade dos registros, a chave primária foi construída pela combinação do código da instituição, código do curso, nome do curso e município.

O fluxo seguido para a construção das bases iniciou-se com a extração da base de desempenho do Enade, contendo o código do curso do estudante, suas respostas ao questionário e sua nota geral. Essa nota foi utilizada como referência para o cálculo das notas médias por curso, transformando-se as notas individuais em uma média agregada por código de curso.

Em seguida, empregou-se a base de microdados do Censo da Educação Superior para realizar um filtro dos cursos englobados pelas condições estabelecidas na pesquisa, realizando o cruzamento pelo código do curso e filtrando as condições pela Base de Dados do Censo da Educação Superior. Os filtros aplicados selecionaram exclusivamente cursos de graduação presenciais ofertados por instituições situadas no município de São Paulo, abrangendo tanto instituições públicas quanto privadas e considerando as principais categorias administrativas e organizações acadêmicas. Também foram incluídos cursos classificados nos graus acadêmicos tradicionais (bacharelado, licenciatura e tecnólogo), além de considerar a condição de gratuidade quando aplicável.

Após o processo de integração e filtragem, obteve-se uma base de cursos válidos — com as regras estabelecidas para a pesquisa — utilizada no restante do trabalho e composta pela média das notas de 1.081 cursos distintos. O schema resultante contemplou os dados de nome da instituição, código e nome do curso, município de oferta e código institucional.

Com a base de cursos válidos consolidada, deu-se início à etapa de criação das bases de dados temáticas. O objetivo foi estruturar três conjuntos de dados distintos — infraestrutura, percepções dos estudantes e características socioeconômicas — sempre relacionados à chave primária construída e à nota média dos cursos. Para o grupo temático de infraestrutura, utilizou-se novamente os microdados do Censo da Educação Superior, resultando em uma base contendo a chave primária, a nota média e todas as variáveis institucionais disponibilizadas sobre condições de infraestrutura física e organizacional, conforme descritas no Dicionário de Dados da Educação Superior.

Para o grupo temático de percepções dos estudantes, calculou-se a moda das respostas dos alunos às questões do questionário aplicado pelo Enade, agregadas pela mesma chave primária. Foram incluídas todas as questões de percepção referentes à avaliação do curso e da instituição,

correspondentes às perguntas numeradas de 27 a 68, registradas no formato *QE₁xnoDicionriodeVariveisdosMicr*

Para o grupo temático de características socioeconômicas, procedeu-se de forma similar, calculando a moda das respostas associadas ao perfil socioeconômico dos estudantes, também agregadas pela chave primária. Foram consideradas as perguntas numeradas de 1 a 26, igualmente descritas no Dicionário de Variáveis dos Microdados do Enade 2023.

Por fim, após os agrupamentos, foi feita a conversão de determinadas variáveis qualitativas em quantitativas, por meio de técnicas como one-hot encoding ou label encoding, de modo a viabilizar sua utilização em modelos estatísticos e de aprendizado de máquina.

Por fim, a média das notas dos estudantes de cada curso foi categorizada em duas classes de desempenho, baixo (notas inferiores à 38.55) e alto (notas superiores à 38.55), a partir da aplicação de um modelo de Mistura Gaussiana (GMM), cujo resultado pode ser verificado na Figura 1. Essa técnica foi utilizada para identificar grupos com diferentes formatos e variâncias na distribuição das notas, permitindo a separação automática dos cursos com base em padrões estatísticos presentes nos dados. Para definir a quantidade ideal de grupos do modelo, utilizamos o Critério de Informação Bayesiano (BIC). Assim, o número de componentes foi selecionado no ponto em que o BIC atinge seu menor valor. Conforme indicado pelo método do cotovelo aplicado aos resultados, ilustrado na Figura 1, a divisão do conjunto em 2 grupos é a mais adequada.




Figura 1: Divisão identificada pela GMM e Método do cotovelo (BIC) para definição do número de grupos..

4.2 Determinação das variáveis relevantes em cada dimensão

Após o tratamento da base de dados, foi realizada a análise das variáveis de cada dimensão, com o objetivo de identificar as mais relevantes dentro de cada dimensão. Nesta etapa, uma análise exploratória inicial foi realizada a partir do cálculo de medidas de tendência central e de dispersão para diferentes variáveis. Esse primeiro contato com os dados possibilitou uma percepção inicial sobre as dimensões. Nessa etapa, também analisamos a distribuição das notas de cada curso em relação à variáveis selecionadas das três dimensões considerados, bem como a frequência das respostas aos questionários de percepção do estudante sobre seu processo formativo e ao Questionário do Estudante, que contempla questões socioeconômicas.

Para determinar as variáveis com maior correlação com o desempenho dos alunos de um curso, utilizamos as correlações de Cramér de V e Coeficiente de Spearman, respectivamente, para variáveis qualitativas e quantitativas, conforme destacada na fundamentação teórica deste trabalho.

Optou-se por essas técnicas estatísticas devido à sua adequação ao tipo de variável analisada, uma vez que o Cramér's V mede a intensidade da associação entre variáveis categóricas em tabelas de contingência, enquanto o Spearman permite identificar relações monotônicas entre variáveis numéricas. A vantagem da utilização dessas medidas é que elas não pressupõem normalidade dos dados e possibilitam capturar tanto associações lineares quanto não lineares, fornecendo uma análise mais robusta e realista das correlações nesse estudo.

4.3 Predição do Desempenho dos Cursos de Educação Superior

Na fase da criação dos modelos dos algoritmos de Árvore de Decisão e Floresta Aleatória, foram utilizadas as bibliotecas pandas e scikit-learn do Python. A primeira foi amplamente utilizada para tratamento e para a extração das bases de dados já limpas. Já a biblioteca scikit-learn foi utilizada para a criação, treino e teste dos modelos.

O conjunto de dados foi dividido entre treino e teste de forma estratificada, ou seja, mantendo as proporções originais das classes em ambos os conjuntos, separando 80% dos dados para treino e 20% para teste.

A otimização dos parâmetros foi realizada por meio de um *Grid Search*, que realiza uma busca por diferentes combinações de hiperparâmetros, aplicando validação cruzada para identificar a configuração que resulta no melhor desempenho do modelo. Os domínios de busca do *grid* foram definidos de forma empírica, sem critérios prévios de otimização.

As métricas utilizadas para avaliar os modelos foram F-Score e acurácia.

5 Resultados

O repositório no GitHub com todas as contribuições desse trabalho pode ser acessado pelo link https://github.com/Gabriela-Alcaide/Analises_de_padroes_na_educacao_superior_em_instituicoes_brasileiras.

5.1 Análise da influência das dimensões

Foi realizada uma análise preliminar dos dados sobre o desempenho dos estudantes e as variáveis de cada dimensão, com o objetivo de identificar relações iniciais entre suas características e o desempenho no ENADE.

Os resultados iniciais das notas podem ser resumidos por medidas de tendência central e de dispersão, como média, mediana, moda e desvio padrão. Esses valores dão uma visão geral da distribuição do desempenho médio dos estudantes dos cursos de educação superior presenciais paulistas, conforme apresentado na Tabela 2. Observa-se uma média de desempenho de 45 pontos, valor próximo à mediana e à moda do conjunto. O desvio padrão de 10 pontos mostra uma variação moderada entre as notas, evidenciada também pela diferença entre o desempenho mínimo e o máximo encontrado. Além disso, o histograma da Figura 3 mostra que há uma maior concentração de estudantes com notas entre 40 e 55 pontos, reforçando a proximidade entre média, mediana e moda.

Estatística	Valor
Mínimo	18.90
1º Quartil (Q1)	35.95
Quantil 33%	39.65
Mediana	45.30
Quantil 66%	49.57
3º Quartil (Q3)	52.21
Máximo	76.99
Média	44.86
Moda	40.97
Desvio Padrão	10.18

Figura 2: Medidas de tendência central e dispersão das médias das notas do ENADE por curso.




Figura 3: Distribuição da média das notas do ENADE por curso..

O conjunto de variáveis da dimensão infraestrutura pode ser subdividido em dois grupos principais: docentes e acesso a periódicos. No que se refere às características dos docentes (como a quantidade total de docentes, o número de docentes com doutorado, o número de docentes com mestrado, entre outras) foi identificada uma correlação de Pearson de 0,23 entre a quantidade total de docentes da instituição e o desempenho dos alunos. Esse dado sugere que o aumento no número de docentes no curso está associado a um desempenho superior dos estudantes desse curso, como ilustrado na Figura 4.

Dado o baixo nível de correlação entre as características de acesso a periódicos e as notas dos estudantes, decidimos, neste momento inicial, concentrar nossas análises nas demais frentes.




Figura 4: Boxplot das notas do ENADE por quantidade de docentes na instituição..

Na dimensão percepção dos estudantes, observa-se que as respostas dos alunos sobre o curso apresentam uma correlação fraca com o desempenho médio deles no ENADE por curso. Ao analisar este grupo, verificamos que, de forma geral, a percepção dos alunos sobre o curso que

realizaram tende a ser negativa. Destaca-se a frequência das respostas nas questões que possuem as maiores correlações na Figura 5, embora ainda pequenas (com um módulo máximo de 0,17 para a correlação de Pearson), com o desempenho dos alunos.




Figura 5: Frequência das respostas dos alunos às questões de percepção do curso..


Na dimensão socioeconômica, é explorada a distribuição das médias das notas dos estudantes por curso com base nas respostas às questões aplicadas. Foi verificado que fatores como a escolaridade dos familiares, o tempo de dedicação aos estudos e a situação financeira da família impactam o desempenho na avaliação do ensino superior.

5.2 Variáveis relevantes em cada dimensão

Foram aplicadas técnicas para estudo de correlação e associação entre as variáveis independentes da base de dados e a categoria de desempenho dos estudantes (baixo ou alto). Com isso, foram definidas as variáveis de cada dimensão com maior relevância para a determinação de desempenho.

Na dimensão infraestrutura da instituição educacional, foram observadas correlações altas. As variáveis desse grupo temático que apresentaram maiores associações com o desempenho do estudante foram: *NO_CURSO*; *NO_MUNICIPIO*; *NO_MUNICIPIO_IES*; *NO_MANTENEDORA*; *NO_BAIRRO_IES*; *TP_CATEGORIA_ADMINISTRATIVA*; e *NO_MICRORREGIAO_IES* (ver Tabela 1). Todas as variáveis são qualitativas categóricas, e foram testadas com Cramér de V. As figuras 6 e 7 ilustram a distribuição das notas em relação às categorias.

Tabela 1: Variáveis de infraestrutura com maior correlação com a média de desempenho por curso.






Figura 7: Boxplot das variáveis de infraestrutura selecionadas.

Na dimensão percepção do estudante acerca do curso e da instituição, foram observadas correlações baixas. As variáveis desse grupo temático que apresentaram maiores associações com o desempenho do estudante foram: *QE_I40*; *QE_I51*; *QE_I54*; *QE_I59*; *QE_I64*; *QE_I65*; e *QE_I68*. Assim como para o grupo anterior, as variáveis escolhidas foram selecionadas por Cramér de V. A figura 8 ilustra a distribuição das notas em relação às categorias.

Variável	Descrição	Índice	p-value
<i>QE_I40</i>	Foram oferecidas oportunidades para os estudantes superarem dificuldades?	0,16	$7,20^{-5}$
<i>QE_I51</i>	As atividades do TCC contribuíram para qualificação?	0,17	$1,71^{-5}$
<i>QE_I54</i>	Os estudantes participaram de avaliações periódicas do curso?	0,21	$2,33^{-8}$
<i>QE_I59</i>	A instituição dispôs de quantidade suficiente de funcionários para apoio?	0,15	$3,25^{-4}$
<i>QE_I64</i>	A biblioteca dispôs das referências bibliográficas que os estudantes necessitaram?	0,16	$1,82^{-4}$
<i>QE_I65</i>	A instituição contou com acesso a obras virtuais?	0,17	$4,30^{-5}$
<i>QE_I68</i>	A instituição dispôs de refeitório, cantina e banheiros em condições adequadas?	0,16	$8,87^{-5}$

Tabela 2: Variáveis de percepção com maior correlação com a média de desempenho por curso.




Figura 8: Boxplot das variáveis de percepção selecionadas..

Na dimensão socioeconômica, as variáveis que apresentaram correlações altas. Nesse grupo temático, as maiores associações com o desempenho foram: *SEXO*; *QE_I06*; *QE_I09*; *QE_I10*; *QE_I11*; *QE_I25*; e *QE_I26*. Para todas as variáveis, por pertencerem ao tipo qualitativo categórico, foi utilizado Cramér de V. A figura 9 ilustra a distribuição das notas em relação às características.

Variável	Descrição	Índice	p-value
SEXO	Sexo	0,57	$1,80^{-69}$
QE_I06	Onde e com quem você mora atualmente?	0,25	$1,00^{-12}$
QE_I09	Situação financeira	0,44	$7,06^{-38}$
QE_I10	Situação de trabalho	0,45	$5,35^{-42}$
QE_I11	Tipo de bolsa ou financiamento para custear as mensalidades	0,27	$1,02^{-11}$
QE_I25	Qual o principal motivo para você ter escolhido este curso?	0,44	$4,05^{-37}$
QE_I26	Principal razão para ter escolhido a instituição	0,25	$2,83^{-10}$

Tabela 3: Variáveis socioeconômicas com maior correlação com a média de desempenho por curso.




Figura 9: Boxplot das variáveis de características socioeconômicas selecionadas..

5.3 Predição do Desempenho dos Cursos de Educação Superior

5.3.1 Configuração

A partir da seleção das variáveis relevantes realizada na etapa anterior em cada dimensão, foram desenvolvidos três modelos, um para cada dimensão, com o objetivo de avaliar a capacidade discriminatória das principais variáveis de cada dimensão.

Para treinamento, utilizou-se uma divisão estratificada de 80% dos dados mantendo a proporção das classes no conjunto de treino e teste. Ademais, as mesmas instituições foram mantidas em todas as dimensões, garantindo comparabilidade entre os resultados.

Os modelos passaram por ajuste fino (tuning) via Grid Search, testando combinações de hiperparâmetros com o objetivo de otimizar o desempenho, avaliado por meio da medida F1. Para a árvore de decisão, variaram-se o critério de impureza (Gini e Entropia), a profundidade máxima da árvore, o número mínimo de amostras por folha (min_samples_leaf) e de amostras exigido para uma divisão interna (min_samples_split). O resultado do ajuste das árvores dos grupos temáticos pode ser observado na Tabela 4.

O mesmo processo realizado com árvores de decisão foi replicado para florestas aleatórias. Porém, os parâmetros variados no processo de Grid Search foram: número de árvores na floresta (n_estimators), profundidade máxima nas árvores (max_depth) e quantidade de amostras exigidas para uma divisão interna nas árvores (min_samples_split).

Grupo Temático	Critério de Impureza	Profundidade Máxima	Mín. de amostras por folha	Mín. de amostras por divisão interna
Percepção	Gini	-	4	10
Infraestrutura	Entropia	5	4	2
Socioeconômico	Gini	3	4	2

Tabela 4: Melhores parâmetros encontrados no Grid Search - Árvores de Decisão.

5.4 Árvore de Decisão

O desempenho dos modelos de árvore de decisão por dimensão são mostrados na Tabela 5.4, e as matrizes de confusão são mostradas na Figura 11.

Para a dimensão percepção, o modelo apresentou desempenho global intermediário, com acurácia de 64,9%, precisão de 60,6% e sensibilidade de 64,9%, na média ponderada, resultando em um f1-score médio de 61,5%. Esses resultados indicam que essas variáveis possuem um poder discriminatório mediano sobre o desempenho acadêmico. A variável mais importante foi a correspondente à questão “A instituição dispôs de refeitório, cantina e banheiros em condições adequadas que atenderam as necessidades dos seus usuários?”.

Para a dimensão socioeconômica, os resultados foram superiores, com bom desempenho, a acurácia foi de 88,3%, precisão de 88,6% e sensibilidade de 88,3%, na média ponderada. A variável de maior importância foi Sexo, sugerindo influência relevante desse fator no desempenho médio do curso.

Na dimensão infraestrutura, observou-se o melhor desempenho geral entre os modelos, com acurácia de 91,0%, sensibilidade de 91,0%, precisão de 92,0% e medida f1 de 91,1%, na média

ponderada. Os melhores parâmetros encontrados foram: Entropia, profundidade máxima de 5, 4 amostras mínimas por folha e 2 por divisão interna. A variável mais importante foi Nome do Curso, indicando forte associação com o desempenho médio do curso.

Os resultados das árvores de decisão evidenciam que fatores institucionais influenciam mais fortemente o desempenho acadêmico do que aspectos perceptivos, e um pouco mais fortemente do que aspectos socioeconômicos.

Dimensão	Acurácia	Precisão	Sensibilidade	Medida F1
Percepção	0,6489	0,6061	0,6489	0,6153
Infraestrutura	0,9095	0,9197	0,9095	0,9114
Socioeconômico	0,8829	0,8858	0,8829	0,8839

Tabela 5: Desempenho dos modelos de Árvore de Decisão por dimensão (médias ponderadas)..




Figura 10: Matrizes de confusão das Árvores de Decisão por dimensão..

A regra para o ramo menos profundo da melhor árvore de decisão da dimensão de infraestrutura pode ser entendida como: O curso pertence ao conjunto Agronegócio, Agronomia, Arquitetura E Urbanismo, Biomedicina, Ciências Biomédicas, Controle Ambiental, Enfermagem, Engenharia Agrônômica, Engenharia Ambiental, Engenharia Ambiental E Sanitária, Engenharia Ambiental E Urbana, Engenharia Civil, Engenharia Da Computação, Engenharia De Alimentos, Engenharia De Computação, Engenharia De Controle E Automação, Engenharia De Gestão, Engenharia De Instrumentação Automação E Robótica, Engenharia De Produção, Engenharia De Produção Mecânica, Engenharia Elétrica, Engenharia Florestal, Engenharia Mecânica, Engenharia Mecânica Aeronáutica, Engenharia Química ?. Na prática, esta regra infere que os cursos excluídos (Estética E Cosmética, Farmácia, Fisioterapia, Fonoaudiologia, Gestão Ambiental, Gestão Hospitalar, Medicina, Medicina Veterinária, Nutrição, Odontologia, Radiologia, Zootecnia) geralmente possuem notas altas.

Além disso, a regra para o segundo ramo menos profundo, ao responder a primeira pergunta de forma positiva, possui o segundo maior poder de divisão entre as categorias e consegue extrair bem quais são os cursos que geralmente possuem notas negativas. A regra pode ser transformada na seguinte pergunta: O curso pertence ao conjunto Agronegócio, Agronomia, Arquitetura E Urbanismo, Biomedicina, Ciências Biomédicas, Controle Ambiental, Enfermagem, Engenharia Agrônômica, Engenharia Ambiental, Engenharia Ambiental E Sanitária, Engenharia Ambiental E Urbana? De acordo com o modelo, em caso de resposta positiva, a probabilidade do curso possuir nota alta é maior.




Figura 11: Árvore de decisão da dimensão de Infraestrutura..

5.4.1 Florestas Aleatórias

Grupo Temático	Núm. de Árvores	Profundidade Máxima das Árvores	Mín. de amostras por divisão interna
Percepção	100	10	2
Infraestrutura	400	10	10
Socioeconômico	400	10	5

Tabela 6: Melhores parâmetros encontrados no Grid Search - Floresta Aleatória.

O desempenho dos modelos de floresta aleatória por dimensão são mostrados na tabela 5.4.1 e na figura 12 são mostradas as matrizes de confusão.

Para a dimensão percepção, os melhores parâmetros encontrados foram: limite máximo de profundidade em 10, 2 amostras mínimas por folha e com 100 árvores de decisão. O modelo apresentou desempenho global moderado, com acurácia de 66,5%, precisão de 61,2% e sensibilidade de 66,5%, resultando em um f1-score médio de 61,4%, considerando médias ponderadas. Esses resultados indicam que essas variáveis possuem um poder discriminatório mediano sobre o desempenho acadêmico. “As atividades realizadas durante seu trabalho de conclusão de curso contribuíram para qualificar sua formação profissional?” foi a pergunta que mais ajudou o modelo a discriminar os resultados dos cursos.

Para a dimensão socioeconômica, os resultados foram superiores, com bom desempenho, a acurácia foi de 87,2%, precisão de 87,2% e sensibilidade de 87,2%, na média ponderada. A variável de maior importância foi Sexo, ressaltando a importância deste fator.

No dimensão infraestrutura, observou-se o melhor desempenho geral entre os modelos, com acurácia de 91,5%, sensibilidade de 91,6%, precisão de 91,5% e medida f1 de 91,5%, na média ponderada. Os melhores parâmetros encontrados foram: 10 como profundidade máxima, 10 amostras mínimas por divisão interna e com 400 árvores de decisão. A variável mais importante para a melhor floresta aleatória do grupo temático de infraestrutura foi Nome do Curso.

Os resultados das florestas aleatórias reforçam os resultados das árvores de decisão, e ressaltam que o grupo temático mais relevante é, de fato, o de infraestrutura, além de indicar que as variáveis socioeconômicas também possuem relevante influência.

Dimensão	Acurácia	Precisão	Sensibilidade	Medida F1
Percepção	0,6648	0,6119	0,6648	0,6142
Infraestrutura	0,9148	0,9158	0,9148	0,9152
Socioeconômico	0,8723	0,8723	0,8723	0,8723

Tabela 7: Desempenho dos modelos de Floresta Aleatória por dimensão (médias ponderadas)..




Figura 12: Matrizes de confusão das Florestas Aleatórias por dimensão..

6 Discussão e Conclusão

A investigação dos fatores que influenciam o desempenho acadêmico em cursos de ensino superior presencial do Estado de São Paulo é fundamental para direcionar políticas públicas de melhoria da educação. O presente trabalho busca definir a dimensão com maior influência sobre o desempenho médio dos estudantes nos cursos, de forma a permitir políticas direcionadas e assertivas.

Foi realizado um estudo sobre a correlação das variáveis de cada dimensão com o desempenho acadêmico médio dos estudantes dos cursos. O objetivo dessa etapa foi definir quais variáveis seriam utilizadas para treinamento dos modelos de Aprendizado de Máquina.

Na aplicação de modelos de Árvore de Decisão, o grupo da dimensão infraestrutura teve o melhor poder discriminatório, superando a dimensão socioeconômica ou de percepção, apresentando F1-score de 91,5%. A aplicação das Florestas Aleatórias reforçou esse resultado, evidenciando a força discriminatória que as variáveis da dimensão infraestrutura têm sobre o desempenho dos cursos. As Florestas Aleatórias têm um desempenho ligeiramente melhor que as Árvores de Decisão, destacando a robustez desse método de aprendizagem de máquina.

Diante dos resultados obtidos, conclui-se que o desempenho médio dos cursos está mais fortemente associado às condições estruturais e organizacionais das instituições do que às características socioeconômicas dos estudantes ou às percepções sobre o curso. A identificação consistente desses padrões pelos dois métodos de aprendizado supervisionado adotados demonstra que melhorias em infraestrutura, disponibilidade de docentes e organização acadêmica tendem a produzir maior impacto sobre o rendimento geral dos cursos. Ademais, a localização da instituição desempenha papel importante, pois implica diferenças no acesso a transporte, segurança e

recursos educacionais, elementos que podem afetar o desempenho acadêmico dos estudantes.

7 Referências

- Aho, K., Derryberry, D. and Peterson, T. (2014), Model selection for ecologists: the worldviews of AIC and BIC. Acesso em: <<https://sciences.ucf.edu/biology/d4lab/wp-content/uploads/sites/23/2020/02/Aho-et-al-2014.pdf>>
- Allen, M. (Ed.). (2017). The SAGE encyclopedia of communication research methods. SAGE publications. Acesso: <https://books.google.com.br/books?hl=pt-BR&id=4GFCDgAAQBAJoi=fndpg=F>
- BASE DOS DADOS. Censo da Educação Superior 2023. Versão [inserir versão, se houver]. São Paulo: Base dos Dados, 2025. Dataset. Disponível em: <https://basedosdados.org/dataset/a3b57cca-ff80-4bf2-8bac-c145109e06a7>
- BRASIL. Lei nº 10.861, de 14 de abril de 2004. (2004). Institui o Sistema Nacional de Avaliação da Educação Superior (SINAES) e dá outras providências. Diário Oficial da União.
- BRASIL. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP). Exame Nacional de Desempenho dos Estudantes – ENADE: Perguntas Frequentes. Disponível em: <<https://www.gov.br/inep/pt-br/aceso-a-informacao/perguntas-frequentes/exame-nacional-de-desempenho-dos-estudantes-enade>>.
- BRASIL. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep). Saiba quais estudantes serão avaliados no Enade 2023. Disponível em: <<https://www.gov.br/inep/pt-br/centrais-de-conteudo/noticias/enade/saiba-quais-estudantes-serao-avaliados-no-enade-2023>>
- BRASIL Ministério da Educação. (2019). INEP divulga indicadores que avaliam cursos e instituições. Disponível em: <https://portal.mec.gov.br/ultimas-noticias/212-educacao-superior-1690610854/83581-inep-divulga-indicadores-que-avaliam-cursos-e-instituicoes>.
- Burnham, K. P., Anderson, D. R. (2004). Multimodel Inference Understanding AIC and BIC in Model Selection. Disponível em: <<https://sites.warnercnr.colostate.edu/wp-content/uploads/sites/73/2017/05/and-Anderson-2004-SMR.pdf>>
- Carvalho, H. M. (2014). Aprendizado de Máquina voltado para Mineração de Dados: Árvores de Decisão. Monografia (Graduação) - UnB, 98. Disponível em: <https://core.ac.uk/download/pdf/196880926>
- Cohen, J. (1988). Statistical power analysis for the behavioral sciences (2nd ed.). Disponível em: <https://www.taylorfrancis.com/books/mono/10.4324/9780203771587/statistical-power-analysis-behavioral-sciences-jacob-cohen>.
- Corcovia, L. O., Alves, R. S. (2019). Aprendizagem de Máquina e Mineração de Dados: avaliação de métodos de aprendizagem. Revista Interface Tecnológica, 16(1), 90-101. Disponível em: <https://revista.fatectq.edu.br/interfacetecnologica/ptBR/article/view/562>.
- da Silva, J. (2018). Fatores que influenciam o desempenho acadêmico no curso de medicina (Master's thesis, Universidade da Beira Interior (Portugal)). Disponível em: <https://www.proquest.com/docview>
- da Silva Rezende, C. C., Cantarino, L. A. B., de Souza, P. F., Alves, T. O. M., Campos, R. S. (2022). O impacto de aspectos socioeconômicos no desempenho de estudantes de Sistemas de

Informação no ENADE. Revista Brasileira de Informática na Educação, 30, 157-181. Disponível em: <https://journals-sol.sbc.org.br/index.php/rbie/article/view/2093/1929>.

dos Santos, M. J. D. C., Vilhena, E. M. D. S. R., Antonelli, R. A., Meurer, A. M. (2020). Diferenças no desempenho acadêmico a partir das características socioeconômicas, demográficas, comportamentais e psicológicas de estudantes portugueses da área de negócios. Revista Pensamento Contemporâneo em Administração, 14(2), 111-129. Disponível em: <https://www.redalyc.org/journal/441>

Drton, M., Plummer, M. (2017). A Bayesian Information Criterion for Singular Models, Journal of the Royal Statistical Society Series B: Statistical Methodology. Disponível em: <<https://academic.oup>

Dubova, M., Chandramouli, S., Gigerenzer, G., Grünwald, P., Holmes, W., Lombrozo, T., Marelli, M., Musslick, S., Nicenboim, B., Ross, L.N., Shiffrin, R., White, M., Wagenmakers, E., Bürkner, P., Sloman, S.J. (2025). Is Ockham's razor losing its edge? New perspectives on the principle of model parsimony. Disponível em: <<https://doi.org/10.1073/pnas.2401230121>>

Economou, P. (2023). A clustering algorithm for overlapping Gaussian mixtures. Disponível em: https://www.researchgate.net/publication/373146934_A_clustering_algorithm_for_overlapping_Gaussian_mixtures

Fernandes, T. R., Passador, C. S. (2023). Contexto socioeconômico e infraestrutura escolar no desempenho acadêmico: revisão sistemática da literatura. Regae: Revista de Gestão e Avaliação Educacional, 12(21). Disponível em: <http://educa.fcc.org.br/pdf/regae/v12n21/2318-1338-regae-12-21-e84346.pdf>.

Figueiredo Filho, D. B., Silva Júnior, J. A. (2009). Desvendando os Mistérios do Coeficiente de Correlação de Pearson (r). Revista política hoje, 18(1), 115-146. Disponível em: https://dirin.s3.amazonaws.com/drive_materias/1666287394.pdf.

Huang, H., Liao, Z., Wei, X. (2023). Combined Gaussian Mixture Model and Pathfinder Algorithm for Data Clustering. Entropy. Disponível em: https://www.researchgate.net/publication/371652526_Combined_Gaussian_Mixture_Model_and_Pathfinder_Algorithm_for_Data_Clustering

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA. Censo da Educação Superior. Disponível em: <https://www.gov.br/inep/pt-br/areas-de-atuacao/pesquisas-estatisticas-e-indicadores/censo-da-educacao-superior>

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA. Divulgação de Resultados do Censo da Educação Superior 2023. Disponível em: <https://download.inep>

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA. Microdados ENADE 2023. Disponível em: <https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/ENADE>.

Lindholm, A., Wahlström, N., Lindsten, F., Schön, T. B. (2019). Supervised machine learning. Department of Information Technology, Uppsala University: Uppsala, Sweden. 112. Disponível em: https://project.inria.fr/quidiasante/files/2021/06/cours_supervised_ml.pdf.

Lira, S. A. (2004). Análise de correlação: abordagem teórica e de construção dos coeficientes com aplicações. Dissertação de Mestrado - Universidade Federal do Paraná. Disponível em: https://www.ipardes.pr.gov.br/sites/ipardes/arquivos_estritos/files/documento/2019-09/sachiko_dissertacao2004.pdf.

Medeiros Filho, A. E. C. de, Silva, L. S., Pontes Júnior, J. A. F. (2020). Fatores socioeconômicos e o desempenho dos estudantes de Educação Física no ENADE. Educação Linguagem,

7(Especial 2), 87–99. Disponível em: <https://cienciaesociedade.com/wp/wp-content/uploads/2020/07/8_{REdLi2}0>

Miot, H. A. (2018). Análise de correlação em estudos clínicos e experimentais. *Jornal Vascular Brasileiro*, 17(4), 275–279. Disponível em: <https://www.scielo.br/j/jvb/a/YwjG3GsXpBFRZLQhFQG45R>

Riqueti, G. A., Ribeiro, C. E., Zárate, L. E. (2018). Classificando perfis de longevidade de bases de dados longitudinais usando Floresta Aleatória. *KDMiLe*, 33-40. Disponível em: <https://sol.sbc.org.br/index.php/kdmile/article/view/27382/27196>.

Sathyanarayanan, S., Tantri, B. R. (2024). Confusion matrix-based performance evaluation metrics. *African Journal of Biomedical Research*, 27(4S), 4023-4031. Disponível em: <https://www.researchgate.net/profile/Sathyanarayanan-Swaminathan/publication/386347454_{ConfusionMatrix-BasedperformanceEvaluationMetrics/links/674e9e453d17281c7df6b440/Confusion-Matrix-Based-Performance-Evaluation-Metrics.pdf}>.

Schwarz, G. (1978). Estimating the Dimension of a Model. *The Annals of Statistics*. Disponível em: <http://www.jstor.org/stable/2958889>

Spearman, C. (1904). The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1), 72–101. Disponível em: <https://www.jstor.org/stable/1422689?seq=1>.

Souza, H. V. L. de, Neiva, D. H., Calvalcanti, R. P., Rodrigues, L. R., Gomes, A. S., Adeodato, P. J. L. (2017). Uma Análise preditiva de desempenho dos cursos no ENADE com base no perfil socioeconômico e desempenho no ENEM dos alunos. *Anais dos Workshops do VI Congresso Brasileiro de Informática na Educação (WCBIE 2017)*, 684–693. Disponível em: <http://milanesa.ime.usp.br/rbie/index.php/wcbie/article/view/7454/5250>.

Suleiman, I. B., Okunade, O. A., Dada, E. G., Ezeanya, U. C. (2024). Key factors influencing students' academic performance. *Journal of Electrical Systems and Information Technology*, 11(1), 41. Disponível em: <https://link.springer.com/article/10.1186/s43067-024-00166-w>.

Tiwari, A. (2022). Supervised learning: From theory to applications. In *Artificial intelligence and machine learning for EDGE computing* (pp. 23-32). Academic Press. Disponível em: <https://www.sciencedirect.com/science/article/pii/B9780128240540000265>.

Underhill, N., Smith, J. (2015). Context-Dependent Score Based Bayesian Information Criteria. Disponível em: <https://projecteuclid.org/journals/bayesian-analysis/volume-11/issue-4/Context-Dependent-Score-Based-Bayesian-Information-Criteria/10.1214/15-BA980.pdf>

Wenskovitch, J. E. (2019). Dimension Reduction and Clustering for Interactive Visual Analytics. Disponível em: <https://vtechworks.lib.vt.edu/server/api/core/bitstreams/168e7cec-4ec7-4f4b-86df-492dd771c031/content>.

Mukaka, M. M. (2012). A guide to appropriate use of correlation coefficient in medical research. *Malawi Medical Journal*, 24(3), 69–71. Disponível em: <https://www.ajol.info/index.php/mmj/article/view/>