

Análise de padrões de desempenho na educação superior presencial paulista

Title: *Analysis of performance patterns in São Paulo's face-to-face higher education*

Título: *Análisis de patrones de desempeño en la educación superior presencial paulista*

Drielly de Moraes Guerreiro
Universidade de São Paulo (USP)
ORCID: [0000-0000-0000-0000](#)
driellymoraes@usp.br

Gabriela Carvalho Vitorino
Universidade de São Paulo (USP)
ORCID: [0000-0000-0000-0000](#)
gabrielaventurin@usp.br

Gabriela Alcaide
Universidade de São Paulo (USP)
ORCID: [0000-0000-0000-0000](#)
gabriela.alcaide@usp.br

Rodrigo Gonçalves Cardoso
Universidade de São Paulo (USP)
ORCID: [0000-0000-0000-0000](#)
digo.gcardoso@usp.br

Resumo

Este estudo investiga os fatores que influenciam o desempenho dos estudantes no Exame Nacional de Desempenho dos Estudantes (ENADE), com foco em variáveis socioeconômicas, percepções sobre a formação acadêmica e infraestrutura das Instituições de Ensino Superior (IES). Utilizando microdados do ENADE e do Censo da Educação Superior, as notas dos cursos foram classificadas em quatro categorias: ruim, média ruim, média boa e boa. Após o tratamento dos dados, serão aplicadas técnicas estatísticas, como o coeficiente de Spearman e o Cramér de V, para identificar as variáveis mais correlacionadas ao desempenho. Em seguida, conjuntos de fatores serão submetidos a modelos supervisionados, como Árvores de Decisão e Florestas Aleatórias, para avaliar o poder preditivo de cada grupo. O objetivo é verificar quais dimensões exercem maior influência sobre os resultados dos estudantes e gerar insumos para políticas públicas e estratégias institucionais de melhoria da qualidade do ensino superior.

Palavras-chave: ENADE; desempenho acadêmico; fatores socioeconômicos; infraestrutura educacional; aprendizado de máquina.

Abstract

This study aims to analyze the factors influencing the academic performance of higher education students in Brazil, using data from the National Student Performance Exam (ENADE) and from the Higher Education Census. Socioeconomic characteristics, students' perception of their education and institutional infrastructure will be investigated. Supervised machine learning classification models will then be applied to identify which category best discriminates student performance in each selected course.

Keywords: Higher Education; Academic Performance; ENADE; Machine Learning; Data Analysis; Correlation; Evaluation Metrics.

Resumen

Este trabajo tiene como objetivo analizar los factores que influyen en el rendimiento académico de los estudiantes de educación superior en Brasil, utilizando datos del Examen Nacional de Desempeño de los Estudiantes (ENADE) e del Censo de Educación Superior. Se investigarán características socioeconómicas, percepción de los estudiantes sobre la formación e infraestructura institucional. Posteriormente, se aplicarán modelos de clasificación basados en

aprendizaje automático supervisado para identificar qué categoría discrimina mejor el rendimiento de los estudiantes en cada curso seleccionado.

Palabras clave: *Educación Superior; Rendimiento Académico; ENADE; Aprendizaje Automático; Análisis de Datos; Correlación; Métricas de Evaluación.*

1 Introdução

O desempenho dos alunos em instituições de ensino superior constitui um fator de extrema relevância não apenas para as próprias universidades, mas também para o desenvolvimento social e econômico do país. O rendimento acadêmico está diretamente associado à formação de profissionais mais qualificados, ao fortalecimento da competitividade nacional e à promoção de inovação. Nesse sentido, compreender os elementos que influenciam esse desempenho, especialmente quando avaliado por meio da prova do Exame Nacional de Desempenho de Estudantes (ENADE), torna-se essencial para subsidiar políticas públicas mais eficazes, apoiar a gestão institucional e fornecer insumos que possibilitem aprimorar a qualidade do ensino. Assim, o estudo do desempenho acadêmico extrapola o interesse meramente acadêmico e revela sua importância como ferramenta estratégica para a sociedade.

Apesar de haver avanços recentes em pesquisas que buscam identificar os fatores relacionados ao desempenho estudantil, ainda permanecem lacunas importantes, principalmente quando se considera a complexidade e a diversidade da vivência universitária. Muitos trabalhos anteriores concentraram-se em aspectos isolados, como o perfil socioeconômico ou o desempenho em avaliações específicas, sem integrar de maneira abrangente os múltiplos elementos que compõem a realidade do estudante. Esse cenário reforça a necessidade de estudos que articulem diferentes dimensões — desde a percepção dos alunos em relação aos cursos até a infraestrutura das instituições — de modo a evidenciar, com maior precisão, quais fatores exercem maior influência sobre os resultados obtidos. A abordagem integrada e multidimensional, portanto, representa um caminho promissor para análises mais consistentes e para a formulação de estratégias assertivas de melhoria.

Diversos estudos prévios já buscaram compreender o impacto de fatores variados no desempenho acadêmico. Silva (2018), por exemplo, investigou o impacto de mudanças de residência, região de origem e expectativas de dificuldades no rendimento de alunos do primeiro ano de Medicina da Universidade da Beira Interior. O autor concluiu que as dificuldades antecipadas pelos estudantes foram as variáveis com maior relação com o desempenho, ainda que sua pesquisa não tenha considerado dimensões como fatores socioeconômicos ou de infraestrutura institucional. Já Medeiros Filho et al. (2020) analisaram os resultados do ENADE de mais de 15 mil estudantes e demonstraram que aqueles com apoio financeiro de bolsas ou programas governamentais obtiveram melhor desempenho, enquanto alunos de baixa renda ou que trabalhavam em regime integral tiveram resultados inferiores. Esses trabalhos reforçam a importância de ampliar a análise para diferentes esferas da experiência universitária, o que motiva a presente investigação.

Diante desse panorama, formula-se a seguinte questão de pesquisa: entre os diversos fatores relacionados à trajetória universitária, quais grupos de características exercem maior influência sobre o desempenho dos alunos no ENADE? A investigação busca considerar de forma conjunta variáveis como as percepções dos estudantes sobre a formação recebida, seus dados socioeconômicos e as condições de infraestrutura das instituições, permitindo identificar combinações mais significativas e capazes de direcionar ações efetivas.

Com base nesse problema, o presente trabalho tem como objetivo principal reunir e analisar dados provenientes do ENADE e dos microdados do Censo da Educação Superior, de forma a identificar quais grupos de informações apresentam maior correlação com o desempenho acadê-

mico, seja de maneira positiva ou negativa. A intenção é compreender em que medida variáveis de diferentes naturezas — institucionais, individuais e estruturais — se relacionam com os resultados dos estudantes, oferecendo subsídios para a elaboração de políticas educacionais mais eficazes e estratégias de gestão mais alinhadas às necessidades reais das instituições.

A metodologia proposta fundamenta-se na utilização de dados do ENADE e dos microdados da Educação Superior referentes a cursos presenciais, públicos e privados do estado de São Paulo. Inicialmente, será realizado o tratamento e a organização das informações, incluindo a aplicação de medidas de centralidade, como médias e modas, para resumir as notas dos estudantes e as percepções mais frequentes por curso. Variáveis qualitativas serão transformadas em quantitativas por meio de técnicas como one-hot encoding e label encoding, enquanto as médias das notas dos cursos serão categorizadas em três classes de desempenho: bom, médio bom, médio ruim e ruim. Em seguida, os dados serão analisados por meio de medidas de correlação estatística, utilizando o Cramér de V para variáveis qualitativas e o coeficiente de Spearman para variáveis quantitativas, a fim de identificar os fatores mais relevantes em cada grupo temático. Por fim, os conjuntos de variáveis serão submetidos a algoritmos supervisionados de classificação, como Árvores de Decisão e Florestas Aleatórias, avaliados a partir de métricas como acurácia, precisão, sensibilidade, F-score, área sob a curva ROC (AUC-ROC) e matriz de confusão. Esse percurso metodológico permitirá tanto compreender a importância relativa de cada grupo de características quanto verificar a capacidade preditiva dos modelos em relação ao desempenho dos estudantes.

Além desta introdução, o trabalho está estruturado nas seguintes seções: Fundamentos Teóricos, que apresentam os conceitos e definições centrais; Correlação e Associação, que detalham os métodos estatísticos utilizados, como o Cramér de V e o Coeficiente de Spearman; Aprendizado de Máquina, que aborda os algoritmos supervisionados aplicados à análise; Exame Nacional de Desempenho dos Estudantes (ENADE), que contextualiza a avaliação utilizada; Trabalhos Correlatos, que situam esta pesquisa em relação a estudos anteriores; Método, que descreve os procedimentos adotados; e Resultados Parciais, onde são apresentadas as variáveis principais em cada grupo temático. Por fim, o trabalho se encerra com as Referências, que sustentam teoricamente a investigação.

2 Fundamentos teóricos

2.1 Correlação e Associação

Correlação é uma ferramenta estatística que verifica a existência de relações, causais ou não, entre variáveis aleatórias (Figueiredo Filho Silva Júnior, 2009). Ela mensura como a alteração no valor de uma variável está associada à alteração no valor de outra (Pereira, 1951). A seleção do coeficiente apropriado depende da natureza dos dados e do tipo de relação entre eles (Lira, 2004).

2.1.1 Cramér de V

Cramér de V é uma medida estatística utilizada para quantificar a força da associação entre duas variáveis categóricas nominais, ou seja, variáveis cujos valores são nomes ou rótulos sem uma ordem intrínseca (como "estado civil" e "preferência musical") (Allen, 2017).

Seu propósito é condensar a complexidade de uma relação em um único número, que varia de 0 a 1. Um valor de 0 indica que não existe qualquer associação entre as variáveis, sendo variáveis completamente independentes. Em contrapartida, um valor de 1 representa uma associação perfeita, onde conhecer a categoria de uma variável permite prever com exatidão a categoria da outra (Cohen, 1988).

A principal utilidade do Cramér de V é oferecer uma medida padronizada da magnitude da relação, o que permite uma interpretação direta e a comparação entre diferentes estudos ou contextos. Por ser aplicável a tabelas de qualquer dimensão (por exemplo, 2x3 ou 4x4), ele é uma ferramenta versátil para entender o quão forte é o vínculo entre variáveis com múltiplas categorias. A interpretação do valor obtido geralmente segue convenções estabelecidas, onde valores mais altos indicam uma associação mais forte, permitindo ao pesquisador classificar a relação como fraca, moderada ou forte (Kotrlík et al., 2011).

2.1.2 Coeficiente de Spearman

O coeficiente de correlação de postos de Spearman, denotado por ρ (), é uma medida não paramétrica que avalia a força e a direção de uma relação monotônica entre duas variáveis. Diferentemente do coeficiente de Pearson, que mede associações estritamente lineares, o de Spearman não exige que a relação seja linear, mas sim que seja consistente em sua direção, ou seja, à medida que uma variável aumenta, a outra consistentemente aumenta ou diminui (Spearman, 1904). Seu uso é indicado em duas situações principais: quando as variáveis são de natureza ordinal (como escalas Likert ou classificações) ou quando dados contínuos violam as premissas para o uso da correlação de Pearson, como a ausência de distribuição normal (Miot 2018).

A interpretabilidade do coeficiente de Spearman é direta: seu valor varia de -1 a +1, onde o sinal indica a direção da associação (positiva ou negativa) e a magnitude aponta a força. Um valor de +1 indica uma relação monotônica positiva perfeita, -1 representa uma relação monotônica negativa perfeita, e valores próximos de zero sugerem a ausência de uma relação monotônica. O cálculo do coeficiente é conceitualmente a aplicação da fórmula de Pearson sobre os postos dos dados. Primeiramente, os valores de cada variável são ordenados e substituídos por seus respectivos postos (1º, 2º, 3º, etc.), e então a correlação é calculada sobre esses novos valores ranqueados (Mukaka, 2012).

2.2 Aprendizado de Máquina

Aprendizado de Máquina é a área da Inteligência Artificial que busca emular o raciocínio humano em sistemas computacionais. Para isso, aplica raciocínio indutivo sobre os dados utilizados para treinamento, ou seja, parte de exemplos de ocorrências específicas no mundo para generalizar regras sobre o funcionamento dos fenômenos (Monard, 2003).

O Aprendizado de Máquina pode ocorrer de diferentes formas, conforme os dados utilizados para treinamento e o objetivo do aprendizado. As principais categorias são Aprendizado Supervisionado, Aprendizado Não-Supervisionado e Aprendizado por Reforço (Nasteski, 2017).

2.2.1 Algoritmos Supervisionados

Em problemas supervisionados, os dados que alimentam o treinamento do algoritmo são rotulados, ou seja, a classe a que pertencem é explicitamente indicada no registro. O objetivo do aprendizado é prever as classes de registros cujos rótulos ainda não são conhecidas pelo algoritmo (Corcova, 2019).

Existem grupos diferentes de algoritmos de Aprendizado de Máquina Supervisionado, conforme o tipo de dado de seus rótulos. Nos casos em que o rótulo é quantitativo (numérico contínuo ou discreto), o algoritmo é de Regressão. Nos casos em que o rótulo é qualitativo (textual), o algoritmo é de Classificação (Lindholm, 2019). Um problema de Classificação pode ser binário ou multiclasse (Sathyanarayanan, 2024). O foco deste estudo são modelos de Classificação multiclasse.

Árvore de Decisão

Árvore de Decisão é um modelo de Aprendizado Supervisionado, utilizado tanto para problemas de Classificação quanto de Regressão (Carvalho, 2014).

A estrutura da Árvore é composta por nós internos, ramos e folhas. Cada nó interno da Árvore corresponde a um teste sobre um atributo dos dados. Ramos são as arestas que ligam os nós, e representam os possíveis resultados dos testes. Folhas são os nós finais da Árvore, que contêm a classificação predita para o dado (Lindholm, 2019; Carvalho, 2014).

Os atributos considerados para construção da Árvore podem ser quantitativos ou qualitativos categóricos. Isso influencia na maneira como os testes dos nós são definidos (Garcia, 2003).

Para atributos quantitativos, o algoritmo seleciona um ponto de quebra, de forma a minimizar a informação necessária nos nós seguintes da Árvore. São definidos dois ramos partindo do nó em questão, equivalente a valores maiores ou menores que o ponto de quebra. Já no caso de atributos qualitativos categóricos, existem duas possibilidades: definir um ramo para cada valor possível do atributo; e agrupar os valores possíveis do atributo em dois grupos, definindo um ramo para cada um deles (Garcia, 2003).

Floresta Aleatória

Floresta aleatória é um conjunto de Árvores de Decisão (Riqueti, 2018).

As Árvores que compõem a Floresta devem ser heterogêneas (Riqueti, 2018). Para isso, é necessário construir cada Árvore de forma aleatória (Lindholm, 2019). Isso pode ser garantido através das seguintes técnicas: treinar cada Árvore com um subconjunto diferente dos dados de treinamento, possivelmente repetidos; e dispor subconjuntos de atributos diferentes para o treinamento de cada Árvore (Riqueti, 2018).

Avaliação de Algoritmos de Aprendizado Supervisionado

Matriz de Confusão é uma matriz quadrada que relaciona a classe real de cada dado de treinamento à classe predita pelo modelo para o mesmo dado. Seja um conjunto onde o rótulo pode assumir N valores distintos. A Matriz de Confusão para avaliar um modelo preditivo sobre esse fenômeno terá dimensão $N \times N$. O valor de uma célula $[x, y]$ da Matriz será a quantidade de dados cuja classe real é y e a classe predita pelo modelo é x . A interpretação da Matriz permite identificar o comportamento do modelo sobre cada classe dos dados (Sathyanarayanan, 2024;

Tiwari, 2022).

Em problemas de Classificação binária, a classe de interesse do estudo é tratada como positiva. Nesse sentido, são definidos os seguintes valores para avaliação do modelo: TP (True Positive), quando a classe real do dado e a classe predita pelo modelo são positivas; TN (True Negative), quando a classe real do dado e a classe predita pelo modelo são negativas; FP (False Positive), quando a classe real do dado é negativa e a classe predita pelo modelo é positiva; e FN (False Negative), quando a classe real do dado é positiva e a classe predita pelo modelo é negativa (Sathyanarayanan, 2024; Tiwari, 2022). Em problemas de Classificação multiclasse, esses valores são calculados separadamente para cada classe dos dados, que é dada como positiva a cada iteração de cálculo (Sathyanarayanan, 2024).

Existem diferentes métricas para avaliação de um modelo de Classificação. Acurácia mede a proporção de predições corretas ($TP + TN$) dentre todas as predições realizadas pelo modelo ($TP + TN + FP + FN$). É apropriada em conjuntos de dados balanceados, ou seja, em que a proporção das classes no todo é aproximadamente uniforme. Precisão mede a proporção de verdadeiros positivos TP dentre todos os casos preditos como positivos pelo modelo ($TP + FP$). Recall mede a proporção de verdadeiros positivos TP dentro todos os casos verdadeiramente positivos ($TP + FN$). (Sathyanarayanan, 2024; Tiwari, 2022)

3 Trabalhos Correlatos

Silva (2018) investigou o impacto de mudanças de residência, região de origem e opinião prévia sobre dificuldades que seriam enfrentadas ao longo do curso no desempenho acadêmico dos estudantes no 01º ano de Medicina da UBI (Universidade da Beira Interior). Utilizou estatísticas descritivas e inferência, concluindo que, entre os fatores observados, o que teve maior relação com o desempenho foram dificuldades antecipadas. Diferentemente do presente estudo, não trabalha a influência de fatores socioeconômicos, infraestruturais e de percepção sobre o curso no desempenho acadêmico.

Santos (2020) mapeou as principais variáveis na determinação de desempenho acadêmico de estudantes portugueses na área de negócios. Analisou fatores socioeconômicos, demográficos, comportamentais e psicológicos. Formulou hipóteses de pesquisa e aplicou metodologias de teste de hipóteses, como teste T Student, Mann-Whitney e Anova. Diferente do presente estudo, Santos considera apenas a Revisão da Literatura para escolher as variáveis que seriam consideradas na análise. Além disso, não trata a realidade do estado de São Paulo.

Suleiman (2024) estudou a influência de horas de estudo, histórico escolar, atividades extracurriculares e horas de sono no desempenho acadêmico de estudantes. Aplicou estudos de correlação e Regressão Linear. Diferente do presente estudo, não comparou a influência de diferentes esferas no desempenho e utilizou apenas Revisão da Literatura para escolha de variáveis.

Medeiros Filho et al. (2020) investigaram a relação entre os fatores socioeconômicos e o desempenho dos estudantes selecionados no ENADE. A pesquisa utilizou dados de 15.400 estudantes que realizaram a prova em 2017. Os autores concluíram que os estudantes com melhor desempenho foram aqueles com gastos financiados por programas governamentais ou bolsas e que não trabalhavam. Por outro lado, os que obtiveram menor desempenho foram os que tinham

renda familiar de até 1,5 salário mínimo e os que trabalhavam 40 horas ou mais semanais. O presente estudo se diferencia por abordar aspectos além dos socioeconômicos, explorando também as esferas de infraestrutura e percepção.

Rezende, C.C. (2022) realizaram uma análise de como os fatores socioeconômicos dos estudantes respondentes do Enade se relacionaram a nota dos mesmos na avaliação. Na conclusão do trabalho mostrou-se que as variáveis mais relevantes foram a renda familiar, a participação em intercâmbio e bolsa acadêmica, o tipo de financiamento da mensalidade e o tipo de escola do ensino médio. O atual trabalho possui como principal diferença uma maior abrangência quanto aos fatores abordados (foram incluídas variáveis de percepção e de infraestrutura).

Martins (2025) investigou, de forma comparativa, o desempenho estudantil no Enade 2022, do curso tecnológico em Processos Gerenciais, sob a ótica local, regional e nacional no âmbito brasileiro. Os principais resultados indicam um melhor desempenho da maioria das regiões administrativas e metropolitanas do Estado de São Paulo, com destaque a região de Presidente Prudente e São José do Rio Preto, comparados com o Estado de São Paulo, Região Sudeste do Brasil e a Média Nacional. A principal diferença em relação ao presente trabalho é o grupo de análise, sendo o principal público deste trabalho os alunos do curso tecnológico em Processos Gerenciais, ou seja, a diminuição da amostra de pesquisa, além da comparação com a região Sudeste.

Souza et al. (2017) buscaram identificar se um curso alcançaria um conceito igual ou superior a três no ENADE, utilizando o desempenho dos alunos no ENEM e suas características socioeconômicas. A metodologia Cross Industry Standard Process for Data Mining (CRISP-DM) foi utilizada para extrair conhecimento das bases de dados. Os autores concluíram que a Unidade da Federação (UF) e o tempo entre a conclusão do ensino médio e o início da graduação são as variáveis que mais influenciam no resultado. As principais diferenças em relação ao presente projeto estão na utilização do conceito como variável alvo, na utilização dos dados do ENEM e na não utilização dos fatores de infraestrutura e de percepção dos alunos.

Fernandes e Passador (2023) destacam a preocupação constante com a ampliação do acesso à educação, mas a negligência da qualidade do que já é oferecido. Os autores destacam a diferença na quantidade de estudos encontrados, sendo 20 voltados às características socioeconômicas dos estudantes e apenas 8 sobre a infraestrutura das instituições. De modo geral, os trabalhos revisados indicam que os fatores socioeconômicos têm maior impacto no desempenho acadêmico dos alunos do que os aspectos institucionais. Diferentemente de Fernandes e Passador (2023), nosso estudo não se caracteriza como uma revisão, mas sim como uma análise comparativa própria entre fatores socioeconômicos, institucionais e de percepção dos estudantes, aprofundando a relação desses aspectos com o desempenho acadêmico.

4 Método

Para a realização do presente estudo, aplicamos técnicas de tratamento, análise e predição de dados a fim de observar o impacto de diferentes características no desempenho acadêmico de estudantes concluintes do ensino superior no Enade. Nesta análise, selecionamos três grupos de características com potencial influência no desempenho dos estudantes na visão dos autores: características socioeconômicas, infraestrutura da instituição de ensino superior ofertante do curso

e percepção dos estudantes sobre a formação.

Após observação inicial dos Microdados do Enade disponibilizados pelo Inep no *site* do instituto, consideramos, respectivamente, as respostas do Questionário do Estudante, a avaliação dos estudantes sobre seu processo formativo e as informações do Censo da Educação Superior acerca das Instituições de Ensino Superior (IES) - também disponibilizadas pelo Inep - fontes adequadas para a captura das características socioeconômicas, de percepção dos estudantes e de infraestrutura das IES. Portanto, utilizamos esses conjuntos de dados para todo o desenvolvimento desse projeto.

A primeira etapa do projeto é o tratamento dos dados. Com o objetivo de agrupar as informações por curso, aplicamos medidas de centralidade, como a média — das notas obtidas pelos estudantes de cada curso, por exemplo — e a moda — das percepções mais frequentes dos alunos sobre os aspectos do curso. Após os agrupamentos, convertemos determinadas variáveis qualitativas em quantitativas, por meio de técnicas como one-hot encoding ou label encoding, de modo a viabilizar sua utilização em modelos estatísticos e de aprendizado de máquina. Adeais, utilizamos o procedimento contrário para transformar a média das notas dos estudantes de um curso em três classes de desempenho: alto, médio alto, médio baixo e baixo. Por fim, relacionamos as condições de infraestrutura das instituições ofertantes advindas do Censo da Educação Superior com seus respectivos cursos. O procedimento detalhado acima pode ser observado no esquema da Figura 1.




Figura 1: ETL..

Após o tratamento da base de dados, realizamos a análise dos fatores de cada conjunto de características, com o objetivo de identificar os mais relevantes dentro de cada grupo. Nesta etapa, uma análise exploratória inicial foi realizada a partir do cálculo de medidas de tendência central e de dispersão para diferentes variáveis. Esse primeiro contato com os dados possibilitou uma percepção inicial sobre os grupos temáticos. Nessa etapa, também analisamos a distribuição das notas de cada curso em relação à variáveis selecionadas das três frentes consideradas, bem como a frequência das respostas aos questionários de percepção do estudante sobre seu processo formativo e ao Questionário do Estudante, que contempla questões socioeconômicas.

Para determinar os fatores (variáveis) com maior correlação com o desempenho dos alunos de um curso, utilizamos as correlações de Cramér de V e Coeficiente de Spearman, respectivamente, para variáveis qualitativas e quantitativas, conforme destacada na fundamentação teórica deste trabalho. Optamos por essas técnicas estatísticas devido à sua adequação ao tipo de variável analisada, uma vez que o Cramér's V mede a intensidade da associação entre variáveis categóricas em tabelas de contingência, enquanto o Spearman permite identificar relações monotônicas entre variáveis numéricas. A vantagem da utilização dessas medidas é que elas não pressupõem normalidade dos dados e possibilitam capturar tanto associações lineares quanto não lineares, fornecendo uma análise mais robusta e realista das correlações nesse estudo.

Na fase da criação dos modelos dos algoritmos de Árvore de Decisão e Floresta Aleatória, utilizamos as bibliotecas *pandas* e *scikit-learn* do Python. A primeira foi amplamente utilizada para pequenos tratamentos e para a extração das bases de dados já limpas. Já a biblioteca *scikit-learn* foi utilizada para a criação, treino e teste dos modelos, dada sua versatilidade e disponibilidade de ferramentas de aprendizado de máquina.

Iniciamos essa etapa realizando a divisão dos conjuntos de dados entre treino e teste de forma estratificada, ou seja, mantendo as proporções originais das classes em ambos os conjuntos. Para isso, utilizamos a função *train_test_split*, separando 80% dos dados para treino e 20% para teste.

Para a construção do modelo de Árvore de Decisão, utilizamos a função *DecisionTreeClassifier*, que permite ajustar diversos parâmetros, como a profundidade máxima da árvore, o número mínimo de amostras por folha e o método de divisão dos nós. A otimização desses parâmetros foi realizada por meio de um *Grid Search*, implementado na função *GridSearchCV*, que realiza uma busca por diferentes combinações de hiperparâmetros, aplicando validação cruzada para identificar a configuração que resulta no melhor desempenho do modelo. Definimos os domínios de busca do *grid* de forma empírica, sem critérios prévios de otimização.

Por fim, a avaliação dos resultados foi feita com o uso da função *classification_report*, responsável por gerar as métricas de análise de qualidade dos modelos escolhidas, como precisão, revocação (recall), F1-score e acurácia, possibilitando uma análise mais completa do comportamento do modelo em relação a cada rótulo.

Na última etapa do trabalho, nos dedicaremos à avaliação do desempenho dos algoritmos de classificação, verificando qual das técnicas obteve resultados mais promissores. Ao mesmo tempo, analisaremos qual grupo de características produziu modelos com maior assertividade em relação ao desempenho dos estudantes de um curso. Para essas análises, continuaremos utilizando métricas como precisão, sensibilidade, F-score, acurácia e matriz de confusão.

5 Resultados Parciais

5.1 Análise preliminar dos dados por grupo temático

Realizamos uma análise preliminar dos dados sobre o desempenho dos estudantes e os grupos temáticos previamente definidos, com o objetivo de identificar relações iniciais entre suas características e o desempenho no Enade.

Os resultados iniciais das notas podem ser resumidos por medidas de tendência central e de dispersão, como média, mediana, moda e desvio padrão. Esses valores dão uma visão geral da distribuição do desempenho dos estudantes, conforme apresentado na Tabela 1. Observa-se uma média de desempenho de 45 pontos, valor próximo à mediana e à moda do conjunto. O desvio padrão de 10 pontos mostra uma variação moderada entre as notas, evidenciada também pela diferença entre o desempenho mínimo e o máximo encontrado. Além disso, o histograma da Figura 2 mostra que a maior concentração de estudantes obteve notas entre 40 e 55 pontos, reforçando a proximidade entre média, mediana e moda.

Estatística	Valor
Mínimo	18.90
1º Quartil (Q1)	35.95
Quantil 33%	39.65
Mediana	45.30
Quantil 66%	49.57
3º Quartil (Q3)	52.21
Máximo	76.99
Média	44.86
Moda	40.97
Desvio Padrão	10.18

Tabela 1: Medidas de tendência central e dispersão das notas.




Figura 2: Distribuição das notas do ENADE.

Dentre os grupos de características selecionados, observou-se que os aspectos relacionados

à infraestrutura apresentaram uma correlação fraca com o desempenho dos estudantes no Enade. Esse conjunto de características pode ser subdividido em dois grupos principais: docentes e acesso a periódicos. No que se refere às características dos docentes (como a quantidade total de docentes, o número de docentes com doutorado, o número de docentes com mestrado, entre outras) foi identificada uma correlação de Pearson de 0,23 entre a quantidade total de docentes da instituição e o desempenho dos alunos. Esse dado sugere que o aumento no número de docentes está associado a um desempenho superior dos estudantes, como ilustrado na Figura 3. Dado o baixo nível de correlação entre as características de acesso a periódicos e as notas dos estudantes, decidimos, neste momento inicial, concentrar nossas análises nas demais frentes.




Figura 3: Boxplot das notas do ENADE por quantidade de docentes na instituição..

No grupo temático relacionado à percepção dos estudantes, observamos que as respostas dos alunos sobre o curso apresentam uma correlação fraca com o desempenho deles no ENADE. Ao analisar este grupo, verificamos que, de forma geral, a percepção dos alunos sobre o curso que realizaram tende a ser negativa. Destacamos a frequência das respostas nas questões que possuem as maiores correlações na Figura 4, embora ainda pequenas (com um módulo máximo de 0,17 para a correlação de Pearson), com o desempenho dos alunos.

No grupo socioeconômico, exploramos a distribuição das notas dos estudantes com base nas respostas às questões aplicadas. Verificamos que fatores como a escolaridade dos familiares, o tempo de dedicação aos estudos e a situação financeira da família impactam o desempenho na avaliação do ensino superior. Observamos, na Figura 5, que quanto maior a escolaridade da mãe, maior a nota dos estudantes, provavelmente devido ao incentivo ao estudo dentro de casa. Além disso, quanto maior o tempo de dedicação aos estudos, melhor o desempenho na avaliação, indicando que o esforço investido nos estudos reflete diretamente nas notas. Por fim, percebemos que quanto maior a responsabilidade financeira dentro de casa, pior o desempenho dos estudantes, possivelmente devido à instabilidade financeira e à falta de tempo para se dedicar aos estudos, uma vez que os estudantes precisam assumir responsabilidades extras para contribuir com o sustento familiar.




Figura 4: Frequência das respostas dos alunos às questões de percepção do curso..




Figura 5: Distribuição das notas dos estudantes por resposta..

	Escolaridade Mãe	Dedicação aos Estudos	Situação financeira
A	Nenhuma	A. Nenhuma, apenas assisto às aulas	A. Sem renda, financiado por programas governamentais
B	Ensino fundamental (1º ao 5º)	De uma a três horas	Sem renda, financiado pela família
C	Ensino fundamental (6º ao 9º)	De quatro a sete horas	Com renda, ajuda da família
D	Ensino médio	De oito a doze horas	Com renda, sem ajuda externa
E	Ensino superior	Mais de doze horas	Com renda, contribui para a família
F	Pós-graduação		Responsável pelo sustento da família

Tabela 2: Depara das letras dos gráficos.

5.2 Variáveis principais em cada grupo temático

Foram aplicadas técnicas para estudo de correlação e associação entre as variáveis independentes da base de dados e o desempenho dos estudantes. Com isso, foram definidas as variáveis de cada grupo temático com maior relevância para a determinação de desempenho.

No grupo temático sobre infraestrutura da instituição educacional, as variáveis que apresentaram maiores associações com o desempenho do estudante foram: *NO_CURSO* (nome do curso); *NO_MUNICIPIO* (nome do município da instituição); *NO_MUNICIPIO_IES* (nome do município da reitoria da instituição); *NO_MANTENEDORA* (nome da mantenedora da instituição); *NO_BAIRRO_IES* (nome do bairro da instituição); *TP_REDE* (tipo da rede de ensino); e *QT_DOC_EX_INT_DE* (quantidade total de docentes em exercício em tempo integral com dedicação exclusiva). As quatro primeiras são qualitativas categóricas, e foram testadas com Cramér de V. A última é quantitativa, e foi testada com Coeficiente de Spearman.

Variável	Índice	p-value	Variável	Índice	p-value
<i>NO_CURSO</i>	0,54	$1,59^{-113}$	<i>NO_MUNICIPIO</i>	0,35	$6,51^{-5}$
<i>NO_MUNICIPIO_IES</i>	0,34	$1,10^{-6}$	<i>NO_MANTENEDORA</i>	0,44	$6,40^{-18}$
<i>NO_BAIRRO_IES</i>	0,43	$1,94^{-11}$	<i>QT_DOC_EX_INT_DE</i>	-0,23	$4,10^{-13}$
<i>TP_REDE</i>	0,36	$9,26^{-26}$			

Tabela 3: Variáveis de infraestrutura com maior correlação com desempenho.

No grupo temático sobre percepção do estudante acerca do curso e da instituição, as variáveis que apresentaram maiores associações com o desempenho do estudante foram: *QE_I37* (As relações professor-aluno ao longo do curso estimularam você a estudar e aprender?); *QE_I40* (Foram oferecidas oportunidades para os estudantes superarem dificuldades relacionadas ao processo de formação?); *QE_I41* (A coordenação do curso esteve disponível para orientação acadêmica dos estudantes?); *QE_I51* (As atividades realizadas durante seu trabalho de conclusão de curso contribuíram para qualificar sua formação profissional?); *QE_I54* (Os estudantes participaram de avaliações periódicas do curso?); *QE_I65* (A instituição contou com biblioteca virtual ou conferiu acesso a obras disponíveis em acervos virtuais?); e *QE_I68* (A instituição dispôs de refeitório, cantina e banheiros em condições adequadas que atenderam as necessidades dos seus usuários?).

Variável	Índice	p-value	Variável	Índice	p-value
<i>QE_I37</i>	0,12	0,00	<i>QE_I40</i>	0,15	$2,20^{-8}$
<i>QE_I41</i>	0,14	$5,60^{-6}$	<i>QE_I51</i>	0,13	$8,77^{-5}$
<i>QE_I54</i>	0,15	$4,64^{-8}$	<i>QE_I65</i>	0,13	$4,11^{-5}$
<i>QE_I68</i>	0,14	$5,15^{-7}$			

Tabela 4: Variáveis de percepção com maior correlação com desempenho.

No grupo temático sobre variáveis socioeconômicas do estudante, as variáveis que apresentaram maiores associações com o desempenho foram: *SEXO*; *QE_I09* (Qual alternativa a seguir melhor descreve sua situação financeira (incluindo bolsas?); *QE_I10* (Qual alternativa a seguir melhor descreve sua situação de trabalho (exceto estágio ou bolsas?); *QE_I11* (Que tipo de bolsa de estudos ou financiamento do curso você recebeu para custear todas ou a maior parte das mensalidades?); *QE_I17* (Em que tipo de escola você cursou o ensino médio?); *QE_I23* (Quantas

horas por semana, aproximadamente, você dedicou aos estudos, excetuando as horas de aula?); e *QE_I25* (Qual o principal motivo para você ter escolhido este curso?).

Variável	Índice	p-value	Variável	Índice	p-value
<i>SEXO</i>	0,56	$2,15^{-64}$	<i>QE_I09</i>	0,29	$5,99^{-43}$
<i>QE_I10</i>	0,31	$9,19^{-54}$	<i>QE_I11</i>	0,24	$2,44^{-22}$
<i>QE_I17</i>	0,24	$2,62^{-20}$	<i>QE_I23</i>	0,23	$2,54^{-26}$
<i>QE_I25</i>	0,28	$2,34^{-38}$			

Tabela 5: Variáveis socioeconômicas com maior correlação com desempenho.

5.3 Árvores de Decisão

A partir da seleção realizada na etapa anterior em cada grupo temático, foram desenvolvidos três modelos de Árvore de Decisão, um para cada grupo, com o objetivo de avaliar a capacidade discriminatória das principais variáveis de cada conjunto temático.

Para treinamento, utilizou-se uma divisão estratificada de 80% dos dados mantendo a proporção das classes no conjunto de treino e teste. Ademais, as mesmas instituições foram mantidas em ambos os grupos, garantindo comparabilidade entre os resultados.

Os modelos passaram por ajuste fino (tuning) via Grid Search, testando combinações de hiperparâmetros com o objetivo de otimizar o desempenho de cada árvore, avaliado por meio da medida F1. Nos parâmetros avaliados, variaram-se o critério de impureza (Gini e Entropia), a profundidade máxima da árvore, o número mínimo de amostras por folha (*min_samples_leaf*) e de amostras exigido para uma divisão interna (*min_samples_split*).

Para o grupo temático de Percepção, os melhores parâmetros encontrados foram: Gini, sem limite máximo de profundidade, 1 amostra mínima por folha e 5 por divisão interna. O modelo apresentou desempenho global baixo, com acurácia de 28,7%, precisão de 28,7% e sensibilidade de 28,7%, na média, resultando em um f1-score médio de 28,2%. Esses resultados indicam que essas variáveis possuem baixo poder discriminatório sobre o desempenho acadêmico. A variável mais importante foi a correspondente à questão “As relações professor-aluno ao longo do curso estimularam você a estudar e aprender?”.

Para o grupo Socioeconômico, os resultados foram superiores, com acurácia de 53,2%, precisão de 51,4% e média de 52,9%, na média. As ‘baixo’ e ‘alto’ apresentaram as maiores métricas, indicando boa capacidade em reconhecer esses casos, ainda que classes intermediárias tenham sido mais confundidas. Os melhores parâmetros encontrados são: Entropia, profundidade máxima de 3, 1 amostra mínima por folha e 2 por divisão interna. A variável de maior importância foi Sexo, sugerindo influência relevante desse fator no desempenho.

No grupo de Infraestrutura, observou-se o melhor desempenho geral entre os modelos, com acurácia de 60,1%, sensibilidade de 60,0% e precisão de 58,8%, na média, com medida f1 média de 57,3%. O desempenho da classe ‘baixo’ obteve sensibilidade de 93,6%, destacando-se e maior capacidade em identificar essa categoria. Os melhores parâmetros encontrados foram: Entropia, profundidade máxima de 5, 2 amostras mínimas por folha e por divisão interna. A variável mais importante foi Nome do Curso, indicando forte associação com o desempenho médio.

Tabela 6: Desempenho dos modelos de Árvore de Decisão por grupo temático (médias macro).

Grupo Temático	Acurácia	Precisão	Sensibilidade	Medida F1
Percepção	0,2872	0,2872	0,2861	0,2820
Infraestrutura	0,6011	0,5881	0,6007	0,5733
Socioeconômico	0,5319	0,5241	0,5295	0,4853

6 Discussão e Conclusão

A investigação dos fatores que influenciam o desempenho acadêmico em instituições do Estado de São Paulo é fundamental. Esse estudo permite um direcionamento para políticas públicas de melhoria da educação. O presente trabalho busca definir o eixo temático com maior influência sobre o desempenho dos estudantes, de forma a permitir políticas direcionadas e acertivas.

Foi realizado um estudo sobre a correlação das variáveis de cada eixo temático com o desempenho acadêmico dos estudantes. O objetivo dessa etapa é definir quais informações serão utilizadas para treinamento dos modelos de Aprendizado de Máquina.

Entre as características de infraestrutura da instituição de ensino, as variáveis com maior influência sobre o desempenho dos estudantes são curso, o município da instituição, o município onde se localiza a reitoria da instituição, o bairro onde se localiza a reitoria, o tipo de rede de ensino (pública ou privada) e a quantidade total de docentes em exercício com dedicação exclusiva em tempo integral.

Entre os fatores relativos à percepção do estudante sobre seu curso, têm destaque a relação com os professores, contato com a coordenação, impacto percebido na formação profissional, periodicidade de avaliações, acesso digital a livros e condições adequadas no espaço.

Entre as características socioeconômicas, destacam-se fatores como sexo do estudante, situação financeira, situação de trabalho, bolsas de estudo ou financiamento, educação no ensino médio, horas de dedicação aos estudos e motivação para escolha do curso.

Na aplicação de modelos de Árvore de Decisão, o conjunto de variáveis de Infraestrutura teve o melhor poder discriminatório, sugerindo que as características institucionais estão mais diretamente relacionadas às notas médias dos cursos do que os fatores individuais ou de percepção. De modo geral, as métricas indicam que os modelos tendem a separar com maior precisão os extremos do desempenho (baixo e alto), mas apresentam maior confusão nas classes intermediárias (médio baixo e médio alto).

7 Referências

Souza, H. V. L. de, Neiva, D. H., Calvalcanti, R. P., Rodrigues, L. R., Gomes, A. S., Adeodato, P. J. L. (2017). Uma Análise preditiva de desempenho dos cursos no ENADE com base no perfil socioeconômico e desempenho no ENEM dos alunos. Anais dos Workshops do VI Congresso Brasileiro de Informática na Educação (WCBIE 2017), 684–693. Acesso em: <<http://milanesa.ime.usp.br/rbie/index>>.

BRASIL Lei nº 10.861, de 14 de abril de 2004. (2004). Institui o Sistema Nacional de

Avaliação da Educação Superior (SINAES) e dá outras providências. Diário Oficial da União.

BRASIL Ministério da Educação. (2019). INEP divulga indicadores que avaliam cursos e instituições. <<https://portal.mec.gov.br/ultimas-noticias/212-educacao-superior-1690610854/83581-inep-divulga-indicadores-que-avaliam-cursos-e-instituicoes>>.

Carvalho, H. M. (2014). Aprendizado de Máquina voltado para Mineração de Dados: Árvores de Decisão. Monografia (Graduação) - UnB, 98. Acesso em: <<https://core.ac.uk/download/pdf/196880926.pdf>>.

Garcia, S. C. (2003). O Uso de Árvores de Decisão na Descoberta de Conhecimento na Área da Saúde. Acesso em: <<https://lume.ufrgs.br/bitstream/handle/10183/4703/000503532.pdf?sequence=1&isAllowed=y>>.

Riqueti, G. A., Ribeiro, C. E., Zárate, L. E. (2018, October). Classificando perfis de longevidade de bases de dados longitudinais usando Floresta Aleatória. In Symposium on Knowledge Discovery, Mining and Learning (KDMiLe) (pp. 33-40). SBC. Acesso em: <<https://sol.sbc.org.br/index.php/kdmile>>.

Corcova, L. O., & Alves, R. S. (2019). Aprendizagem de Máquina e Mineração de Dados: avaliação de métodos de aprendizagem. Revista Interface Tecnológica, 16(1), 90-101. Acesso em: <<https://revista.fatectq.edu.br/interfacetecnologica/ptBR/article/view/562>>.

da Silva, J. (2018). Fatores que influenciam o desempenho acadêmico no curso de medicina (Master's thesis, Universidade da Beira Interior (Portugal)). Acesso em: <<https://www.proquest.com/docview/2018010101>>.

dos Santos, M. J. D. C., Vilhena, E. M. D. S. R., Antonelli, R. A., Meurer, A. M. (2020). Diferenças no desempenho acadêmico a partir das características socioeconômicas, demográficas, comportamentais e psicológicas de estudantes portugueses da área de negócios. Revista Pensamento Contemporâneo em Administração, 14(2), 111-129. Acesso em: <<https://www.redalyc.org/journal/4417/>>.

Monard, M. C., Baranauskas, J. A. (2003). Conceitos sobre aprendizado de máquina. Sistemas inteligentes-Fundamentos e aplicações, 1(1), 32. Acesso em: <<https://dcm.ffclrp.usp.br/ago/publication/sistemas-inteligentes-cap4.pdf>>.

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA. Microdados Enade 2023. Disponível em: <<https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/enade>>. Acesso em: 13 set. 2025.

Figueiredo Filho, D. B., Silva Júnior, J. A. (2009). Desvendando os Mistérios do Coeficiente de Correlação de Pearson (r). Revista política hoje, 18(1), 115-146. Acesso em: <<https://dirin.s3.amazonaws.com/revista-politica-hoje-18-1-115-146.pdf>>.

Lira, S. A. (2004) Análise de correlação: abordagem teórica e de construção dos coeficientes com aplicações. 2004. Dissertação de Mestrado - Universidade Federal do Paraná, Curitiba. Acesso em: <https://www.ipardes.pr.gov.br/sites/ipardes/arquivos_estritos/files/documento/2019-09/sachiko_dissertacao2004.pdf>.

Medeiros Filho, A. E. C. de, Silva, L. S., Pontes Júnior, J. A. F. (2020). Fatores socioeconômicos e o desempenho dos estudantes de Educação Física no ENADE. Educação Linguagem, 7(Especial 2), 87-99. Acesso em: <<https://cienciaesociedade.com/wp/wp-content/uploads/2020/07/8EdLi2020.pdf>>.

da Silva Rezende, C. C., Cantarino, L. A. B., de Souza, P. F., Alves, T. O. M., Campos, R. S. (2022). O impacto de aspectos socioeconômicos no desempenho de estudantes de Sistemas de Informação no Enade. Revista Brasileira de Informática na Educação, 30, 157-181. Acesso:

<https://journals-sol.sbc.org.br/index.php/rbie/article/view/2093/1929>.

Fernandes, T. R., Passador, C. S. (2023). Contexto socioeconômico e infraestrutura escolar no desempenho acadêmico: revisão sistemática da literatura. *Regae: Revista de Gestão e Avaliação Educacional*, 12(21). Acesso: <<http://educa.fcc.org.br/pdf/regae/v12n21/2318-1338-regae-12-21-e84346.pdf>>.

Nasteski, V. (2017). An overview of the supervised machine learning methods. Horizons. b, 4(51-62), 56. Acesso: <https://www.researchgate.net/profile/Vladimir-Nasteski/publication/328146111_An_overview_of_the_supervised_machine_learning_methods.pdf> .

Lindholm, A., Wahlström, N., Lindsten, F., Schön, T. B. (2019). Supervised machine learning. Department of Information Technology, Uppsala University: Uppsala, Sweden, 112. Acesso: <https://project.inria.fr/quidiasante/files/2021/06/cours_supervised_ml.pdf> .

Sathyanarayanan, S., Tantri, B. R. (2024). Confusion matrix-based performance evaluation metrics. African Journal of Biomedical Research, 27(4S), 4023-4031. Acesso em: <https://www.researchgate.net/publication/386347454_Confusion_Matrix-Based_performance_Evaluation_Metrics/links/674e9e4c674e9e4c674e9e4c_Matrix-Based-Performance-Evaluation-Metrics.pdf>.

Tiwari, A. (2022). Supervised learning: From theory to applications. In Artificial intelligence and machine learning for EDGE computing (pp. 23-32). Academic Press. Accesso: <<https://www.sciencedirect.com/science/article/pii/B9780128240540000265>>.

Suleiman, I. B., Okunade, O. A., Dada, E. G., Ezeanya, U. C. (2024). Key factors influencing students' academic performance. *Journal of Electrical Systems and Information Technology*, 11(1), 41. Acesso: <<https://link.springer.com/article/10.1186/s43067-024-00166-w>>.

Cohen, J. (1988). Statistical power analysis for the behavioral sciences (2nd ed.). Accesso: <<https://www.taylorfrancis.com/books/mono/10.4324/9780203771587/statistical-power-analysis-behavioral-sciences-jacob-cohen>>.

Allen, M. (Ed.). (2017). The SAGE encyclopedia of communication research methods. SAGE publications. Acesso: <<https://books.google.com.br/books?hl=pt-BR&r=id=4GFCDgAAQBAJoi=fndpg=>

Kotrlik, J. W., Williams, H. A., Jabor, M. K. (2011). Reporting and interpreting effect size in quantitative agricultural education research. *Journal of Agricultural Education*, 52(1), 132–142. Acesso: <<https://eric.ed.gov/?id=EJ955682>>.

Mukaka, M. M. (2012). A guide to appropriate use of correlation coefficient in medical research. *Malawi Medical Journal*, 24(3), 69–71. Acesso: <<https://www.ajol.info/index.php/mmj/article/view/81570>>

Miot, H. A. (2018). Análise de correlação em estudos clínicos e experimentais. *Jornal Vascular Brasileiro*, 17(4), 275-279. Acesso: <<https://www.scielo.br/j/jvb/a/YwjG3GsXpBfRZLQhFQG45Rb/?form>>

Spearman, C. (1904). The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1), 72–101. Acesso: <<https://www.jstor.org/stable/1422689?seq=1>>.